

华北电力大学

毕 业 设 计（论 文）

论文题目：火电厂监控界面的操作热点识别方法研究

院　系：自动化系

专　业：测控技术与仪器

班　级：测控 2201

姓　名：敖上上

学　号：220221110601

指导教师：马进

二〇二六年 六月

摘　要

分布式控制系统（DCS）是火电厂实现机组运行监测和集中控制的主要系统，监控界面一般包含按钮、阀门、页面切换图标等操作热点。由于 DCS 监控界面整体分辨率高，部分目标尺寸小、排列密集，在识别的时候容易造成目标特征不清、漏检等现象。本文以 YOLOv8s 目标检测模型为基础，对火电机组 DCS 监控界面的操作热点的识别方法进行了研究。

传统的模板匹配方法在复杂的环境中稳定性差，但是深度学习模型对于高分辨率的图像来说，对于小目标特征会出现特征丢失的现象。为了解决以上问题，本文使用带重叠区域的图像切片预处理方式，把高分辨率的监控截图分成四个有重叠区域的局部图像，在保证原始采样比例不变的情况下提高了模型对于小目标热点的检测效果。

本文使用 YOLOv8s 作为目标检测框架，在实验中根据需要对输入图像分辨率、损失函数参数、数据增强方式等进行修改。经过模型训练之后，选择切片过后的局部图像做识别测试，用 Precision、Recall、F1 分数、mAP 等指标来评价模型的检测效果。

本文主要用切片处理后的监控界面图像做检测对象，在目标分布比较密集的区域中对模型的识别效果进行分析。本文还进行消融实验验证了图像切片方法的合理性以及不同的训练轮数下模型的性能。除此之外，本文还使用手机拍摄的监控界面图像，在一定的距离远离和角度偏移的时候，对模型的泛化能力进行测试。最后将识别后的局部图像还原，进行非极大抑制（NMS）消除重叠框，用原图展示检测结果。

关键词：深度学习，火电机组仿真，小目标检测，YOLOv8s，重叠切片

ABSTRACT

Distributed control system (DCS) is the main system to realize unit operation monitoring and centralized control in thermal power plants. The monitoring interface generally includes buttons, valves, page switching icons and other operating hotspots. Due to the high overall resolution of the DCS monitoring interface, the small size and dense arrangement of some targets, it is easy to cause unclear target features and missed detection when identifying. Based on the YOLOv8 s target detection model, this paper studies the identification method of operation hotspots in DCS monitoring interface of thermal power units.

The traditional template matching method has poor stability in complex environments, but for high-resolution images, the deep learning model will lose features for small target features. In order to solve the above problems, this paper uses the image slice preprocessing method with overlapping regions to divide the high-resolution monitoring screenshots into four local images with overlapping regions, which improves the detection effect of the model on small target hotspots while ensuring that the original sampling ratio remains unchanged.

In this paper, YOLOv8s is used as the target detection framework. In the experiment, the input image resolution, loss function parameters, and data enhancement methods are modified as needed. After the model training, the local image after slicing is selected for recognition test, and the detection effect of the model is evaluated by Precision, Recall, F1 score, mAP and other indicators.

In this paper, the monitoring interface image after slicing is used as the detection object, and the recognition effect of the model is analyzed in the area where the target distribution is dense. This paper also conducts ablation experiments to verify the rationality of the image slicing method and the performance of the model under different training rounds. In addition, this paper also uses the monitoring interface image taken by the mobile phone to test the generalization ability of the model when a certain distance is far away and the angle is offset. Finally, the local image after recognition is restored, and the non-maximum suppression (NMS) is used to eliminate the overlapping box, and the detection results are displayed with the original image.

KEY WORDS: deep learning, thermal power unit simulator, small object detection, YOLOv8s, overlap slicing

目录

摘　　要 I
ABSTRACT II
第 1 章 绪论 1
1.1 研究背景及意义 1
1.1.1 研究背景 1
1.1.2 研究意义 1
1.2 研究现状 2
1.2.1 传统图像处理与视觉识别方法现状 2
1.2.2 基于神经网络与深度学习的目标检测发展 2
1.2.3 大分辨率图像与微小目标检测策略发展 3
1.3 研究内容与主要工作 3
1.4 各章节安排 4
第 2 章 图像识别技术基础 6
2.1 神经网络基础理论 6
2.1.1 人工神经网络基础 6
2.1.2 BP 反向传播算法 8
2.2 YOLOv8 目标检测模型相关分析 9
2.2.1 单阶段检测方法 9
2.2.2 多尺度特征融合结构 10
2.2.3 解耦检测头结构 10
2.3 图像切片与检测后处理 11
2.3.1 图像切片预处理方法 11
2.3.2 坐标还原与非极大值抑制 12
2.4 模型评价指标 13
2.4.1 训练损失函数 13
2.4.2 性能评价指标 13
2.5 本章小结 14
第 3 章 图像预处理与神经网络模型构建 15
3.1 监控界面数据集构建 15
3.1.1 基于 LabelImg 的操作热点标注方法 15
3.1.2 数据集配置文件创建 16
3.2 重叠切片与数据集转换 17
3.3 YOLOv8s 模型训练参数配置 19
3.3.1 模型训练环境配置 19
3.3.2 模型训练参数设置 19
3.4 本章小结 20
第 4 章 模型训练与结果分析 22
4.1 实验平台构建与数据统计 22
4.1.1 实验平台的环境配置 22
4.1.2 数据集样本统计 22
4.2 YOLOv8s 模型训练过程分析 23
4.2.1 训练日志分析 24

4.2.2 模型训练结果 25
4.3 模型识别性能验证 27
4.3.1 测试流程设计 27
4.3.2 测试结果可视化分析 28
4.3.3 泛化能力测试 30
4.3.4 切片还原与非极大抑制处理 32
4.4 消融实验与模型优化分析 33
4.5 本章小结 34
第 5 章 总结与展望 35
5.1 工作总结 35
5.2 后续工作及展望 35
参 考 文 献 37
致 谢 38

第 1 章 绪论

1.1 研究背景及意义

1.1.1 研究背景

火电厂机组运行时，分布式控制系统(DCS)主要用于设备运行监测、过程控制等工作。而运行人员则观察机组运行状态并进行相应操作。DCS 监控界面中存在很多可以进行交互的操作热点，包括页面切换按钮、确认按钮等功能控件，也有电动调节阀、电动机、空气预热器等工艺设备。典型的火电机组 DCS 监控界面及操作热点分布图如图 1-1 所示。

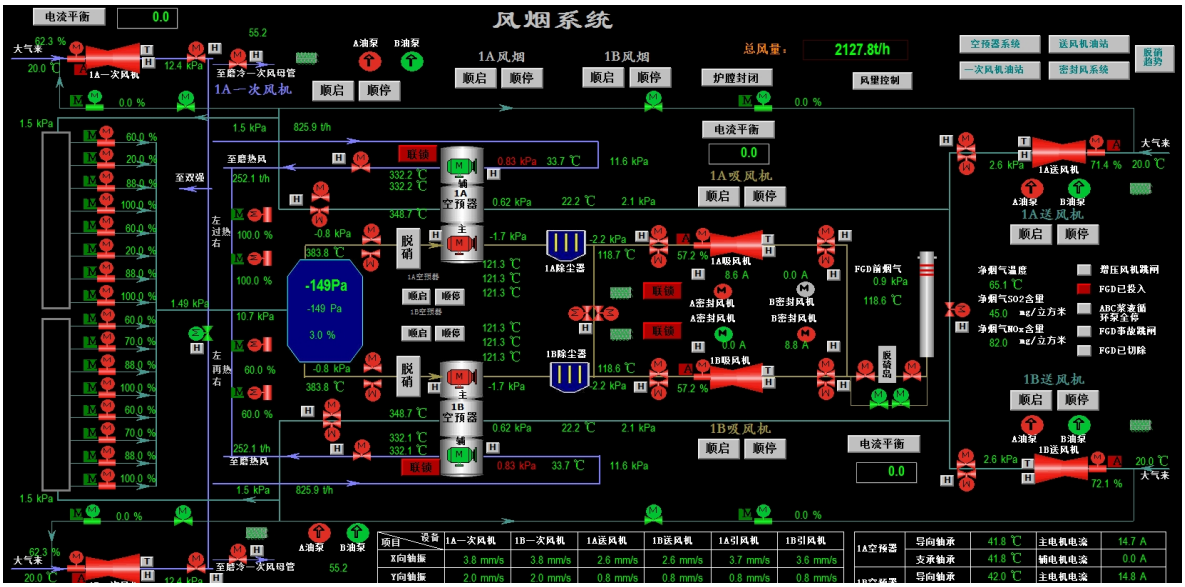


图 1-1 风烟系统监控界面图

本文的主要目的是建立神经网络模型来识别华北电力大学开发的 600MW 火电机组 DCS 监控界面图上的操作热点，监控界面图的分辨率为 1680×1050。从图 1-1 中可以看出，监控界面是纯黑色背景，一张画面上包含了很多设备运行数据、功能模块等，界面中各个功能组件密集排列在一起，很容易造成信息堆叠现象。同时作为人机交互功能点位，整幅高清画面上像素占比较小。直接用传统的深度学习方法对图像进行放缩之后再进行检测识别，会造成微小操作热点丢失细节特征、鲁棒性差等问题，导致识别效果变差[13][15]。

因此，利用计算机视觉技术及轻量化的卷积神经网络对监控界面小目标进行识别、定位，对提高操作热点识别准确率有着较大的作用。还可以一定程度上减少运行人员长时间监屏造成的视觉疲劳和误操作风险，对火电厂监控系统智能化的发展有实际的应用价值。

1.1.2 研究意义

本文使用 YOLOv8s 轻量模型结合图像重叠切片算法，经过实际测试发现该方法可以

满足工业视觉检测的需要，对智慧电厂智能化的建设有较好的应用价值和借鉴意义[20]。下文从三个方面展开分析：

（1）把卷积神经网络理论运用到工业视觉场景当中，结合卷积神经网络相关的理论，学习非线性激活函数、误差反向传播等基础知识[7]，并将这些知识应用到 YOLOv8s 目标检测模型的训练过程之中，从而实现工业监控界面的操作热点识别。经过实验验证了深度学习方法在复杂工业监控场景中是可行的，并且也达到了实验对神经网络模型训练和应用的基本要求。

（2）完善工业高分辨率图像识别技术，针对监控界面图符像素占比低、超大分辨率下小目标特征丢失的问题，采用图像重叠切片的方式解决。重叠切片将原来的操作界面图分为固定尺寸的四个区域，每个区域之间留下一定的重叠部分，这样处理下来操作热点所占像素的比例增大，使模型更容易辨认[16]。

（3）加快工程问题分析速度、解决问题的能力，利用 NVIDIA 显卡和 CUDA 搭建硬件加速环境，可以缩短模型训练时间并提高推理效率。也可以提高模型推理过程中运行的速度[14]。试验结束之后，对整个识别系统运行效果展开验证，现场部署时能够兼顾实时性与识别精度这两个方面的需求，在项目落地过程中具备实用性。

1.2 研究现状

1.2.1 传统图像处理与视觉识别方法现状

早期工业仪表及控制界面自动检测，主要是用传统数字图像处理方法对目标进行识别。该类方法一般要人工构造目标特征，再通过颜色空间转换，边缘检测以及阈值分割等手段来达成图像处理及目标提取。张宁等[24]用颜色差别来创建 LRCD 模型对仪表指针加以提取，并且利用 Hough 变换实现目标轮廓的拟合。张恒博等人[16]把图像从 RGB 颜色空间变换到对光照变化更适应的 HSV 空间，然后用非等位划分法提取图像的颜色特征和灰度特征。在复杂的模式识别研究中，为了减小冗余特征对识别结果的影响，一般会用到特征筛选的方法。赵海涛等人[23]把正交表设计和主成分分析（PCA）应用到汉字识别的研究当中，从中选取特征子集，从而提高分类器的稳定性以及识别能力。

但是传统的机器视觉方法对于图像质量要求高，大多数算法需要人工建立特征，一般要针对具体的场景反复调整参数。当工业现场存在背景干扰、光照变化或者界面结构复杂等情况下，其识别效果就会降低，不能满足现代智慧电厂对于识别精度和运行稳定性的实际需要。

1.2.2 基于神经网络与深度学习的目标检测发展

由于传统的方法对于复杂的场景下的特征表达能力较差，所以研究人员开始把人工神经网络（ANN）用到目标识别、模式分类的任务上[3]。从最初的 BP 反向传播算法、前馈

神经网络结构，到后来的结合小波函数的多模块并行训练方法[22]，神经网络在复杂的特征学习和模式分类方面已经取得了较好的应用效果。

近些年来，基于卷积神经网络 CNN 的深度学习模型已经成为目标检测领域的主要方法。尹宏鹏等[13]认为用判别式表观建模的深层 CNN 可以自动地学习海量数据中的高阶抽象特征。彭明霞等人[15]把融合了特征金字塔 FPN 的 Faster R-CNN 应用到复杂的背景识别当中，证明了深层残差网络加上 Max-pooling 下采样可以更好地提取出目标特征。

工业监控的落地应用中实时性和准确性的矛盾就成了深度学习研究的重点。白雨生、王超主要研究火电机组仿真机 DCS 界面图像识别。白雨生[14]用深度学习对仿真机 DCS 界面标题区域、设备运行状态进行多目标定位和识别；王超[21]认为采用开发自定义控制软件的方式对 DCS 系统进行改造，可以以“机器换人”方式大幅度降低由于频繁负荷变化所造成的主观操作错误率，为深度学习技术在智慧电厂的应用提供算法支持。

1.2.3 大分辨率图像与微小目标检测策略发展

对于大分辨率的监控图像来说，目标像素所占比例很小。直接把高分辨率的大图缩小到传统网络需要的输入尺寸，小目标就会因为严重的下采样而出现细节特征丢失[13]。目前主流策略主要是从图像空间预处理和模型结构改进两个方面进行研究。

带重叠区域的图像切片法被证明可以提高小目标在图像中所占的像素比例。张恒博等[16]采用图像重叠切片的方式把原始图像分成四个互相重叠的部分，这样可以减少目标处于切片边缘的时候出现特征缺失的情况，利于模型对小目标边缘特征的提取。

在目标检测网络结构的研究当中，多尺度特征融合以及小目标检测越来越受到人们的关注。Lu 等[28]在 X 射线微小缺陷检测研究中，在 YOLOv8 模型的基础上加上小目标检测头，使用 BiFPN 特征融合结构来提高模型对微小目标的检测效果。梁凯文等[27]针对国产低算力嵌入式设备的部署需求，在 YOLO11 网络上加上自适应拉伸模块(ASM)和额外的小目标检测头，并且采用算子融合和混合量化的方法，从而达到在低算力环境下完成小目标检测的目的。

1.3 研究内容与主要工作

根据监控界面的特点，本文从图像切片、目标标注、模型训练、目标检测、坐标还原等几个方面对识别过程进行了详细的说明，整体的技术路线如图 1-2 所示。

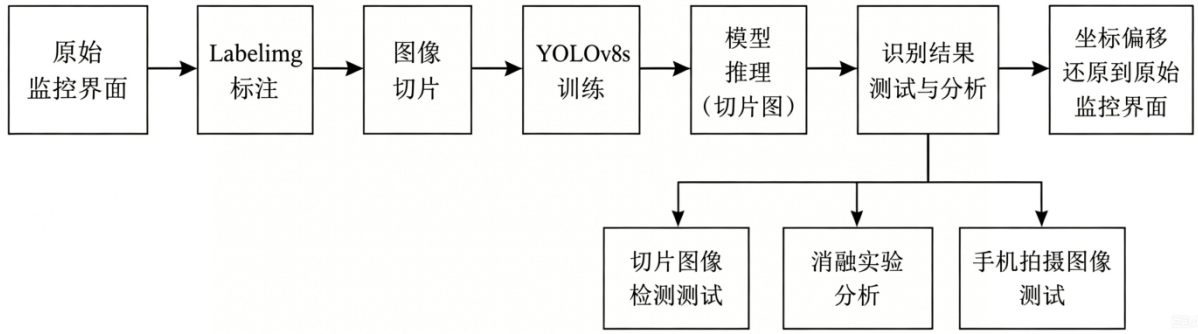


图 1-2 本文操作热点识别总体流程图

整个流程开始的时候会先对原始监控画面进行图像切片操作来加强小目标区的特征信息，减少目标信息丢失，然后对切片后的图像进行标注并形成数据集，最后用 YOLOv8 模型进行训练。模型推理阶段分别对各个切片区域进行目标检测，用非极大值抑制法去除重叠区域的重复检测框；最后用坐标映射的方法把局部检测结果还原到原始监控界面里，得到完整的场景下操作热点。本文主要做了如下工作：

（1）学习卷积神经网络以及 BP 反向传播算法相关理论知识，了解 ReLU、Sigmoid 等激活函数在神经网络中起到的作用。根据火电厂监控界面对识别速度和检测精度的实际需求，对单阶段和双阶段的目标检测算法进行分析，最后选择 YOLOv8s 作为操作热点识别模型，用 Python、PyTorch 以及 Ultralytics 框架搭建深度学习实验环境。

（2）把高分辨率的监控界面分割成四个有重叠区域的局部图像，在保持原始图像细节的基础上，改善小目标输入模型之后的特征保留情况，削减目标处于切片边缘的时候出现的信息缺失状况。图像切片时同步完成目标标注框坐标映射和归一化处理，使得切片后的标签数据可以满足 YOLO 格式训练的要求；对没有目标的切片保留空标签文件用于背景样本训练。

（3）根据火电厂监控界面的实际使用情况制作出操作热点识别的数据集，进行模型的训练以及参数的调节。对界面中的按钮、阀门、跳转图标等目标进行人工标注，得到数据集，并编写配置文件。模型训练时改变输入分辨率、损失函数参数、数据增强方式，用精确度 Precision、召回率 Recall、损失函数 Loss 的变化来分析模型训练的效果。

（4）对模型进行测试，分析识别结果。本文以切片后的监控界面图像作为检测对象，对模型识别效果进行验证，用消融实验分析图像切片方法和不同的训练轮数下模型性能的变化。为了检验模型在实际环境中是否适用，用手机拍摄的监控画面进行测试。最后对切片检测框做坐标偏移还原处理，保证后面完整的界面检测结果。

1.4 各章节安排

各个章节的安排如下：

第一章：绪论。主要对火电厂 DCS 监控界面操作热点识别的研究背景、研究意义进行阐述，结合目前目标检测技术的发展状况，分析高分辨率工业监控界面中小目标识别存在的问题。在此基础上，对本文研究内容以及整体实现流程进行说明。

第二章：介绍论文所用到的有关理论和技术，即卷积神经网络、BP 反向传播算法和常用的激活函数。对 YOLOv8s 模型结构、特征提取过程、损失函数等做简单介绍，重点说明重叠切片、非极大值抑制等图像处理技术。

第三章：完成数据集制作与模型训练相关工作。首先用 LabelImg 标注监控界面的操作热点，再编写 yaml 配置文件。对原始图像做带重叠区域的切片，标签坐标也重新映射归一化。之后使用 YOLOv8s 训练模型，对输入分辨率、损失函数参数、数据增强方式进行修改。

第四章：模型训练结果的测试与分析。根据模型训练过程中 Precision、Recall 和 Loss 的变化情况来观察模型的收敛效果，并用典型的 DCS 监控界面测试模型的识别效果。根据实验过程中出现的小目标漏检、重叠区域重复检测等问题，对模型结果进行分析。

第五章：总结全文主要研究工作，分析目前模型在复杂工业环境下的不足之处，提出以后模型的改进方法和应用前景。

第 2 章 图像识别技术基础

2.1 神经网络基础理论

神经网络是当前计算机视觉领域的重要基础，被广泛应用于图像分类、目标检测和工业视觉识别等任务。与传统依赖人工设计特征的图像处理方法相比，神经网络能够通过多层网络结构自动学习图像中的特征信息，从而提高复杂场景下目标识别的准确性和鲁棒性。在工业视觉领域，基于神经网络的目标检测方法已经成为解决复杂背景和小目标识别问题的重要手段。

火电厂 DCS 监控界面中包含很多按钮、阀门以及页面跳转图标等操作热点，部分目标尺寸小、分布密，传统的图像处理方法在复杂的界面环境下容易造成漏检。因此本文使用基于卷积神经网络的 YOLOv8s 目标检测模型来识别工业监控界面的操作热点。为了方便后面模型的训练以及实验分析，本节将人工神经网络、激活函数和 BP 反向传播算法等有关理论进行介绍。

2.1.1 人工神经网络基础

人工神经网络的研究起源于模仿生物神经元的工作原理。MP 模型属于人工神经网络的基本结构单元，用以表现神经元对输入信号处理的过程。该模型中神经元先接收到来自输入的信号，之后再分别与对应权重相乘相加，再加上偏置项 b，最后经过激活函数得到输出结果。图 2-1 为 MP 神经元的基本构成。

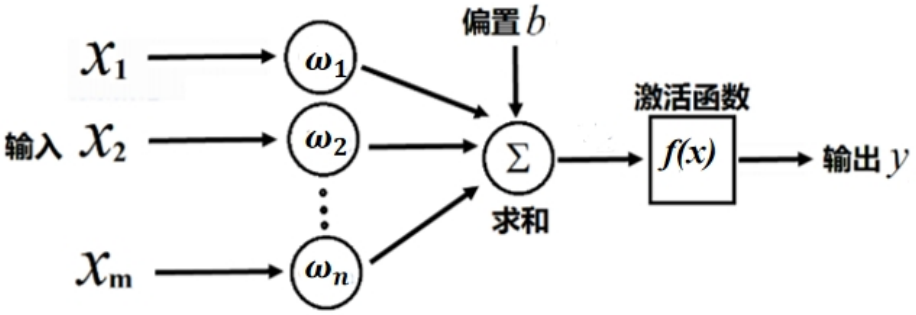


图 2-1 MP 神经元结构示意图

神经元输出结果的计算公式如公式(2-1)所示：

$$y=f\left(\sum_{i=1}^{n} w_i x_i+b\right) \tag{2-1}$$

x_i：输入信号，w_i：对应权重，b：偏置项，f：激活函数，y：神经元输出结果。

多个神经元按一定的方式连接起来就形成了多层人工神经网络结构，然后经过不断地调整网络权重来实现特征的学习。

（1）激活函数就是对神经元输出结果进行非线性变换的神经元，是卷积神经网络里不可缺少的部分。不同的激活函数会对模型的训练效果和网络的收敛速度产生影响。常见的激活函数有 Sigmoid 函数、ReLU 函数和 SiLU 函数等。

（2）饱和型激活函数（Sigmoid）：早期的神经网络多采用 Sigmoid 函数，其数学表达式如公式(2-2)所示:

$$\sigma(x)=\frac{1}{1+e^{-x}} \tag{2-2}$$

Sigmoid 函数可以将输入结果映射到 0 到 1 之间，但是当输入值过大或者过小时，函数的梯度就会变得很小，最后接近于 0，在深层网络训练过程中很容易导致梯度消失的问题，从而影响模型的收敛速度。Sigmoid 函数曲线图像如图 2-2 所示:

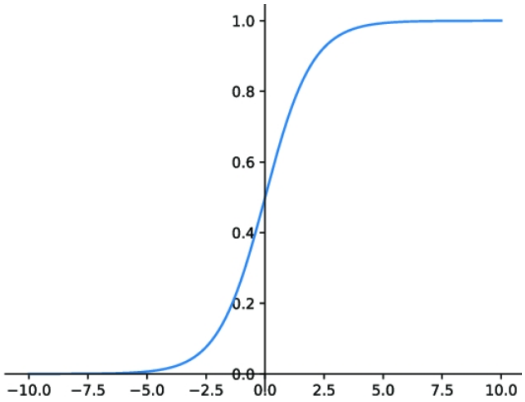


图 2-2 Sigmoid 函数图像

（3）线性整流函数（ReLU）：由于存在梯度消失问题，之后使用 ReLU 函数[3]，其计算公式如(2-3)：

$$f(x)=max(0,x) \tag{2-3}$$

当大于 0 时为直线，梯度恒为 1，具有收敛速度快、可以产生稀疏性等优点，但是容易造成神经元不进行权重更新。ReLU 函数曲线图如图 2-3 所示：

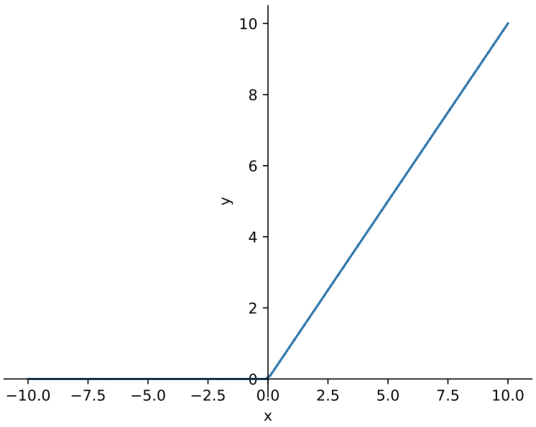


图 2-3 ReLU 函数图像

（4）平滑非线性函数（SiLU）：YOLOv8 模型中使用了 SiLU 作为激活函数[28]。其数

学表达式如公式(2-4)所示：

$$f(x)=x\sigma(x)=\frac{x}{1+e^{-x}} \tag{2-4}$$

与 ReLU 函数相比，SiLU 函数在零点附近的变化更平滑，在模型训练过程中可以保持比较稳定的梯度变化。因此 YOLOv8s 训练时一般收敛较好，对 DCS 监控界面中小目标的识别也有一定的适应性。SiLU 函数曲线图如图 2-4 所示：

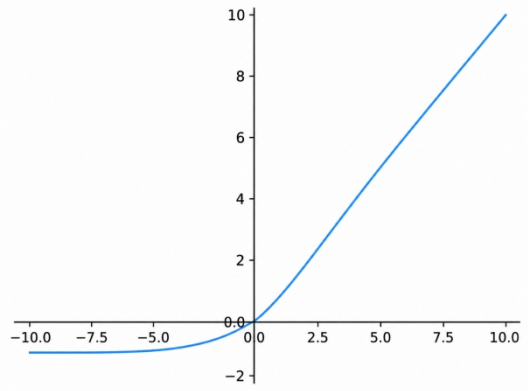


图 2-4 SiLU 函数图像

ReLU 和 SiLU 在深层网络中的收敛效果优于传统 Sigmoid 函数。YOLOv8s 模型将 SiLU 作为主要激活函数，在目标检测的训练过程中能够保持较稳定的状态。

2.1.2 BP 反向传播算法

神经网络训练时，只用前向传播不能完成模型参数的自动调整，因此还要用 BP（Back Propagation）反向传播算法来训练网络[7]。BP 算法的主要作用就是根据模型预测结果和真实标签之间的误差，不断地更新网络中各个权重参数，使得损失函数的值不断减小，让模型的识别效果得到提高。

神经网络经过前向传播之后得到的是当前样本的预测结果，然后用损失函数来计算预测值和真实值之间的误差。BP 算法是根据误差反向传播的结果，逐层从后面一层传送到前面一层，再根据梯度更新网络权重。其参数更新过程如公式(2-5)所示：

$$w=w-\eta\frac{\partial E}{\partial w} \tag{2-5}$$

w：网络权重参数，η：学习率，E：损失函数，$\frac{\partial E}{\partial w}$：损失函数对权重参数的梯度。

在模型训练过程中，学习率会直接影响模型收敛效果。学习率过大时模型训练过程就会产生震荡，学习率过小时模型收敛速度变慢。因此要根据实际训练情况进行学习率参数的调整。

YOLOv8s 模型的训练过程也是用 BP 反向传播算法来完成的。在训练的时候，模型会按照预测框同真实标签之间差别不断改进网络参数，使得损失函数逐渐变小，进而加强对

于操作热点目标的识别水平。图 2-5 为模型的前向传播过程，即预测结果，然后用损失函数计算误差，最后通过 BP 反向传播更新网络参数。在实际训练过程中还要对输入图像的分辨率、损失函数的权重、数据增强方式等加以调节，从而改善模型对于小目标的检测情况。

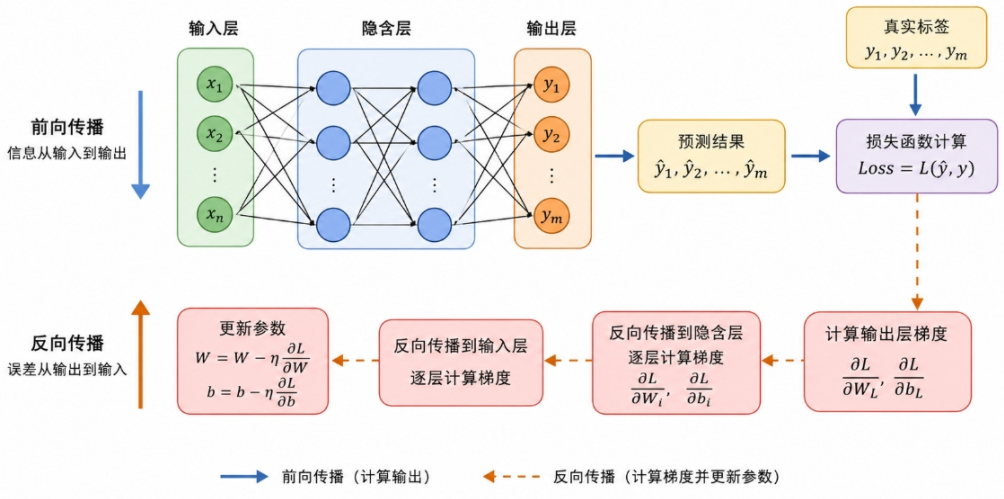


图 2-5 BP 反向传播训练过程示意图

除此之外为了使模型训练稳定，YOLOv8 训练时使用动量参数、权重衰减等手段对网络参数进行优化[28]，可以一定程度上避免模型训练过程中出现过拟合的问题。完成卷积特征提取和网络参数训练之后，就要用目标检测结构对图像中的目标位置和类别进行预测。本文在后面章节中会结合 YOLOv8 模型，对于目标检测有关的结构和实现方式进行介绍。

2.2 YOLOv8 目标检测模型相关分析

2.2.1 单阶段检测方法

目标检测算法大体上可以分为双阶段检测和单阶段检测两种[25]。双阶段检测方法以 Faster R-CNN 为代表，主要过程为先生成候选区域，再对候选目标进行分类和位置回归；单阶段检测方法以 YOLO 系列模型为代表，直接在模型中完成目标位置和类别预测。相比于双阶段检测来说，单阶段模型没有候选区域的生成过程，因此整体检测的速度要快得多。

在本实验的实际识别过程中，模型既要保证有一定的检测精度，也要满足较好的实时性要求，于是本文采用单阶段目标检测方法为主要的研究方案。

YOLOv8 是 YOLO 系列中的最新一代单阶段目标检测模型之一，就网络结构而言，在特征提取以及检测方式上有所改进。本文选择参数规模比较小的 YOLOv8s 模型进行实验研究。相比其它规模较大的模型来说，YOLOv8s 在保证检测速度的同时，对于小目标的识别任务也有较好的适应性，因此更适合用于 DCS 监控界面的识别任务。

2.2.2 多尺度特征融合结构

对于 DCS 监控界面上的操作热点，如果仅仅只用深层特征去进行检测，那么在下采样的过程中，小目标的特征信息就容易变得薄弱，进而对检测的效果造成影响。因此，目标检测模型一般都会把浅层的位置信息和深层的语义特征利用起来，以此来提高对小目标的识别能力。YOLOv8 在网络结构里，采用了一种把 FPN（Feature Pyramid Network）和 PAN（Path Aggregation Network）结合在一起的多尺度特征融合方式[28]。其结构如图 2-6 所示。

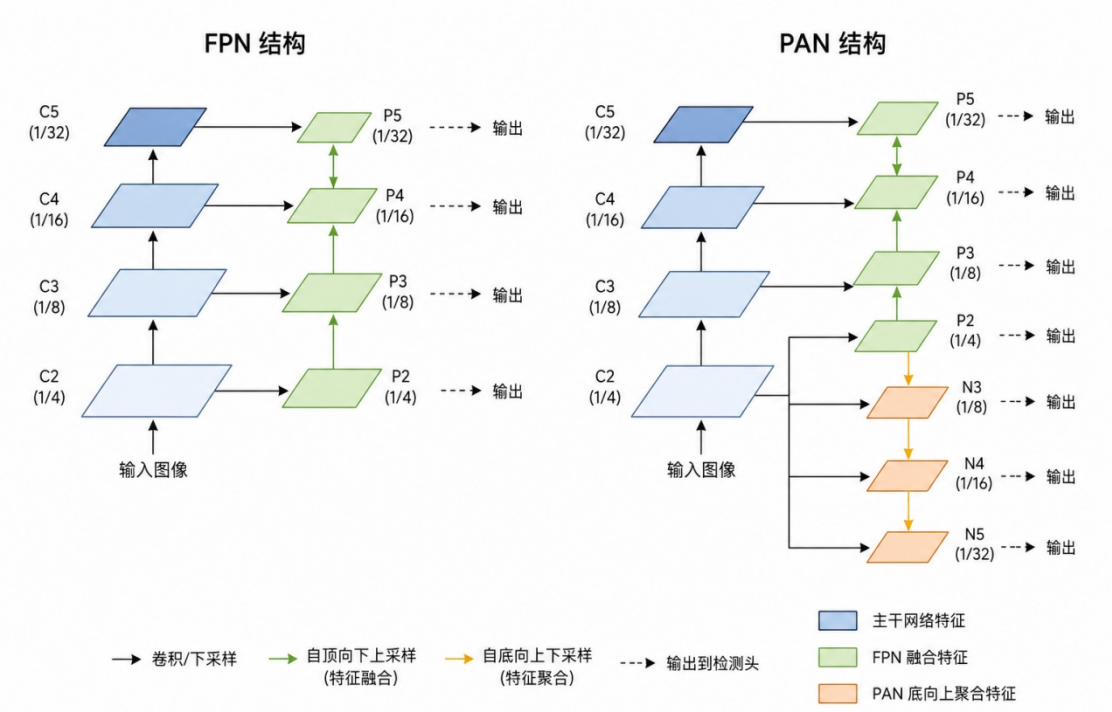


图 2-6 FPN 与 PAN 多尺度特征融合结构图

FPN 所采用的自顶向下结构，能够把深层网络所学到的全局语义特征，传递到浅层网络当中去，这样一来，小目标在深层特征里容易被淹没的问题就得到了解决。而 PAN 的自底向上路径，则反过来把浅层所拥有的精准位置信息传递到深层网络里，从而对深层特征在定位能力方面存在的不足进行了弥补。

在 DCS 监控界面这个场景当中，当把 FPN 和 PAN 结合在一起之后，该结构能够提高对按钮、图标等这一类小目标的识别效果。

2.2.3 解耦检测头结构

解耦检测头采用的方法是将目标分类和边界框回归分别交给不同的部分来完成，分类分支专门用于对目标的类别进行判断，回归分支负责对目标的位置进行预测。图 2-7 给出了结构中所包含的批大小 B，类别数 C，特征图尺寸 H×W，最终输出目标数量 N 等参数。

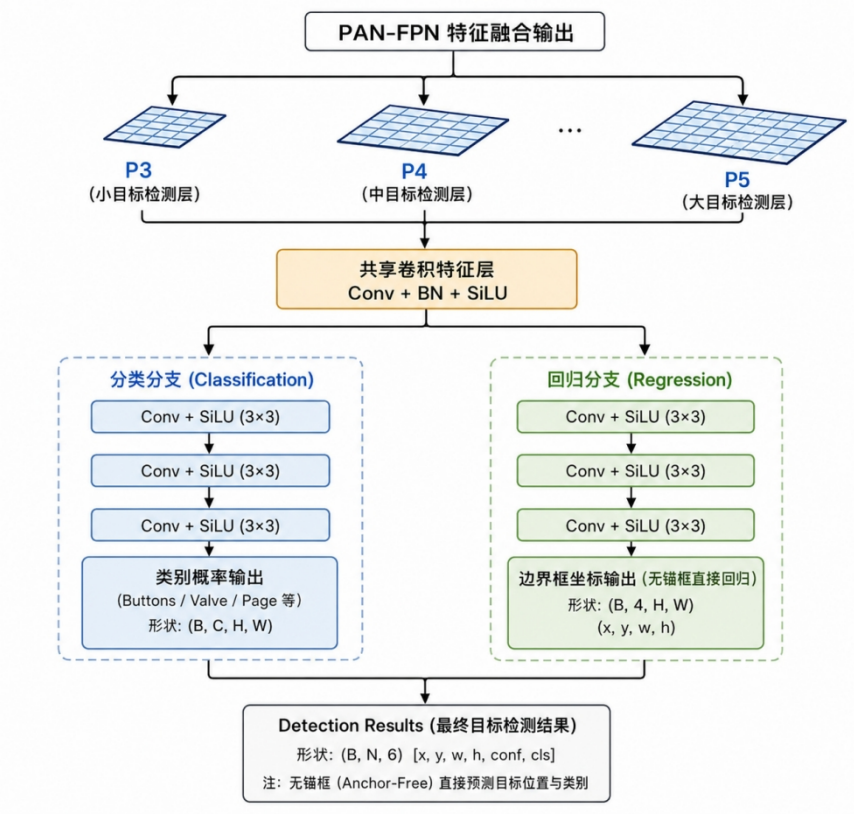


图 2-7 解耦头结构图

解耦的检测头结构中，分类分支完成的是对目标类别的预测，回归分支完成的是边界框坐标的回归。和传统的基于锚框（Anchor-Based）的检测方法不同，YOLOv8 使用的是无锚框（Anchor-Free）的方式，直接对目标位置进行回归预测，而不再是像锚框那样设计了锚框参数来控制。对于 DCS 监控界面的热点识别任务来说，如果检测框位置偏差过大，那么后面热点区域定位的结果就会受到影响。因此模型训练的时候不仅要考虑边界框定位的准确性还要考虑小目标特征的提取能力。

YOLOv8 模型在训练时，会依据预测结果同真实标签间的差别来更新网络参数，同时借助损失函数评判模型当下训练状况[7]。训练过程中损失函数的变化情况可以反映模型参数收敛的趋势。除了网络结构本身之外，输入图像的预处理方式也会对检测效果造成影响，因此后面还要结合图像切片和检测结果后的处理等方法来提高模型对于监控界面中小目标操作热点的识别能力。

2.3 图像切片与检测后处理

2.3.1 图像切片预处理方法

火电厂 DCS 监控界面的图像分辨率为 1680×1050，YOLOv8 模型在训练时需要将图像统一缩放到默认固定的尺寸（640×640）。直接对整张界面进行缩放，小尺寸操作热点在图像中所占的像素比例就会降低，造成部分目标特征不明显，进而影响到模型检测的效果。

为了提高模型对于小目标的检测效果，在训练之前对原始监控界面进行了图像切片处

理，将完整的界面划分成了若干个局部区域，然后分别输入到模型中。本方法在保证图像细节信息的前提下，增大了小目标特征所占比例，改善了模型对于按钮、阀门以及页面跳转图标等操作热点的识别效果。

另外，考虑到有些操作热点处在图像边缘处，如果直接执行普通的切片操作，就容易造成目标被分割的情况发生。因此本文使用带有重叠区域的切片方式，使相邻切片之间有公共区域，减少边缘目标信息缺失给检测结果带来的影响[16]。

图像切片之后还要对目标标注框坐标做同步映射以及归一化处理，使得数据满足YOLO 目标检测模型的训练格式要求。后面章节会根据实验过程来说明图像切片以及坐标处理的方法。

2.3.2 坐标还原与非极大值抑制

完成图像切片检测之后，模型给出的目标坐标都是在当前切片内局部的坐标，不能直接对应到原始监控界面的实际位置上。因此需要将各个切片的检测结果重新映射到原始图像坐标系上，得到完整的界面目标检测结果。

本文使用坐标偏移法来实现检测框的坐标还原。根据不同的切片在原始图像中起始位置的不同，对检测框的坐标进行相应的偏移，进而完成局部坐标到全局坐标的转换。其计算过程如公式(2-6)与公式(2-7)所示：

$$X_{global}=X_{local}+\Delta X \tag{2-6}$$

$$Y_{global}=Y_{local}+\Delta Y \tag{2-7}$$

其中，X_{local}与Y_{local}：切片中的局部坐标，ΔX 与ΔY：当前切片在原始图像中的坐标偏移量，X_{global}与Y_{global}：还原后的全局坐标。

由于图像切片之间存在一定重叠区域，同一操作热点可能会在多个切片中被重复检测。为减少重复检测框对结果造成的影响，本文在检测结果后处理中采用了非极大值抑制（Non-Maximum Suppression，NMS）算法[25]。NMS 算法主要通过计算不同检测框之间的交并比（IoU）来判断目标重叠程度，交并比的计算方式如公式(2-8)所示：

$$IoU=\frac{Area(Box_A \cap Box_B)}{Area(Box_A \cup Box_B)} \tag{2-8}$$

当两个或者多个检测框的 IoU 大于设定阈值的时候，系统就会保留置信度高的检测框，去掉重复检测框，减少同一个目标被多次识别的现象。经过坐标还原以及 NMS 处理之后，各个切片里的检测结果可以重新归入到完整的监控界面当中，给之后的操作热点定位打下基础。

2.4 模型评价指标

在目标检测任务中要关注模型训练过程中损失函数的变化趋势，结合验证集评价指标来对模型的识别效果进行分析。

2.4.1 训练损失函数

损失函数的作用就是反映模型在训练过程中预测值和真实标签之间的差异，它具体的构成有如下几部分。

定位损失（Box Loss），表示的是预测边界框与真实目标边界框的位置误差，数值越小，模型对于目标的定位能力就越强。分类损失（CLS Loss），可以看作是度量模型对目标分类识别准确性的一个标准，它表示的是预测标签和真实标签之间的差距，数值越小，说明模型对于各个类别的样本分类效果越好。分布焦点损失（DFL Loss），属于一种重要的辅助损失函数，在边界框回归任务中主要用来提高目标边缘位置的准确性，一般会和定位损失结合使用，通过两者相互配合来提高检测框预测的准确性以及鲁棒性。

在训练不断推进的过程当中，随着迭代次数在持续地增加，各种损失函数都逐渐地呈现出了减小并且慢慢趋于平稳的一种态势，这就可以对模型当中的参数已经基本完成了优化，同时也能表明网络已经较好地学习到训练集里不同类别样本所具备的那些特征。

2.4.2 性能评价指标

本文采用 Precision、Recall、F1 Score 以及 mAP 等指标，对模型检测效果进行评价。

在目标检测任务中，将正确检测出的目标定义为真正例（True Positive，TP），错误检测出的目标定义为假正例（False Positive，FP），未被检测出的真实目标定义为假负例（False Negative，FN）。具体的指标及公式如下：

（1）精确率（Precision）：真正例所占除去假负例以外的目标比例，其计算公式如(2-9)所示，Precision 越高，模型误检情况越少。

$$P=\frac{TP}{TP+FP}\times 100\% \tag{2-9}$$

（2）召回率（Recall）：是真正例被正确识别的比例，用公式(2-10)表示，Recall 越大，表示漏检例数就越少。

$$R=\frac{TP}{TP+FN}\times 100\% \tag{2-10}$$

（3）F1 分数(F1 score)：F1 分数是 Precision 以及 Recall 的结合度量，如(2-11)所示。

$$F1=\frac{2TP}{2TP+FP+FN} \tag{2-11}$$

（4）平均精度均值（mAP）：平均精度均值（mAP）是评价一个检测模型整体水平的指标。mAP 实际上就是对多个类别平均精度（Average Precision，AP）进行加权平均后得到的结果，表达式如(2-12)所示。

$$mAP=\frac{1}{N}\sum_{i=1}^{N} AP_i \tag{2-12}$$

本文中 mAP50 所对应的，就是将 IoU 阈值设为 0.5 时计算得到的平均精度均值，可以用来评价模型在单一判定标准下检测的表现。mAP50-95 把从 0.5 到 0.95 这个区间内的所有 IoU 阈值下的精度指标都融合在一起，从而可以从更加全面的角度来衡量检测算法的综合性能以及它的鲁棒性。

2.5 本章小结

本章主要对本文所用到的相关理论和技术进行说明。根据人工神经网络的基本原理，对 MP 神经元模型、常见的激活函数和 BP 反向传播算法进行分析，为后面 YOLOv8s 模型的训练提供理论基础。

同时对 YOLOv8 目标检测模型的结构进行介绍，包括单阶段检测方法、多尺度特征融合结构和解耦检测头等。根据 DCS 监控界面中小目标较多的特点，对 YOLOv8s 在小目标检测任务上的适用性进行分析。

除此之外，本章还给出了图像切片预处理、坐标还原、非极大值抑制等方法，也对模型训练中常用的损失函数和性能评价指标做了说明。

通过以上理论分析为后面章节的数据集处理、模型训练和实验结果分析打下了基础。

第 3 章 图像预处理与神经网络模型构建

3.1 监控界面数据集构建

火电厂 DCS 监控界面的操作热点种类很多，有按钮、阀门、页面跳转图标和一些工艺设备元件等。由于各个监控界面的布局方式、颜色风格、目标尺寸等存在一定的差别，在模型训练之前，首先要对数据集进行制作和标准化处理，从而保证后面模型训练的有效性、稳定性。

3.1.1 基于 LabelImg 的操作热点标注方法

在数据集制作时，首先要对监控界面的操作热点进行人工标注。本文使用 LabelImg 进行目标框的选择，然后按照 YOLO 的目标检测格式生成对应的标签文件.txt。标注时主要对按钮、阀门、页面跳转图标和部分可交互设备元件进行矩形框标注，对具有相似特征的操作热点进行统一分类，比如泵（油泵/电泵/汽泵/水泵）。标注过程如图 3-1 所示。



图 3-1 LabelImg 标注示意图

标注结束后得到 Yolo 格式的标签文件，标签中包含目标类别的编号、中心点坐标、宽高信息，均是归一化后的坐标。单个目标标签格式如下：

$$(class\ \ x_{center}\ \ y_{center}\ \ width\ \ height) \tag{3-1}$$

class：类别名称，x_{center},y_{center}：目标中心点坐标，width：目标框宽度，height：目标框高度。

标注完的标签文件部分内容如图 3-2 所示。

```
14 0.349702 0.669048 0.016071 0.010476
14 0.359821 0.765238 0.016071 0.012381
20 0.400000 0.670000 0.016667 0.012381
20 0.411310 0.763810 0.015476 0.011429
16 0.377976 0.717143 0.015476 0.026667
16 0.353274 0.808571 0.016071 0.026667
21 0.328274 0.248095 0.011310 0.025714
22 0.459226 0.280476 0.016071 0.031429
```

图 3-2 标签文件截图

由于 DCS 监控界面中一些操作热点的尺寸比较小，在标注框的位置偏差过大时，会影响模型对目标边界特征的学习。因此在标注的时候，要尽可能保证目标框可以完全包含操作热点区域，并且不能有太多背景区域进入到标注框内。

另外，在某些界面处，目标分布比较密集的时候，相邻目标之间很容易产生边界重叠的问题。标注框重叠太多，在标注的时候要尽量区分相邻目标的边界，不能把多个操作热点一起包含到同一个标注框里。

3.1.2 数据集配置文件创建

完成图像标注之后，就要对数据集展开整理并划分，才能符合 YOLOv8 模型的训练需求。本文根据目标检测数据集常用组织方式，将数据集分为训练集、验证集两部分，其中训练集占 80%，验证集占 20%。

由于火电厂 DCS 监控界面的某些操作热点数量较少，并且小目标样本所占比例较高，如果再单独设置测试集的话，就会使得一些目标类别样本数量过少，进而影响到模型的训练效果。因此本文没有单独设置测试集，而是用验证集和后续典型界面测试结果来综合评价模型的性能。

训练集和验证集的存储结构是用 images 和 labels 两个子目录来存储的。images 用来保存图像文件，labels 用来保存对应的标注文件，标签用 YOLO 格式存储。模型训练数据目录结构图如下图 3-3 所示。

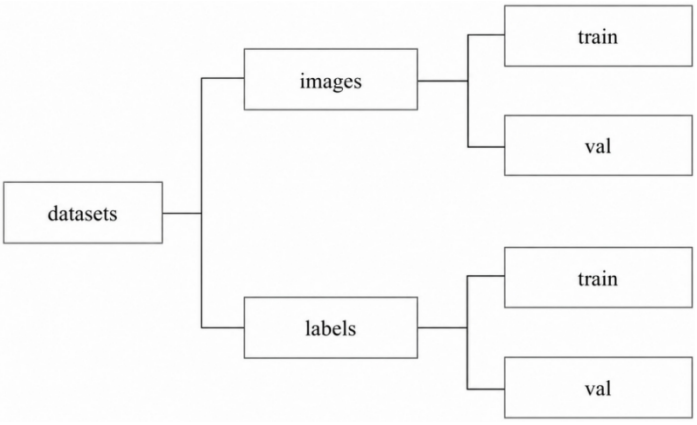


图 3-3 模型训练数据目录结构

为了使 YOLOv8 模型可以读取数据集信息，就需要创建一个包含数据集信息的 yaml 文件。该文件是用来设置训练集和验证集的路径、目标类别的数量以及类别名称等信息的，实际上就是模型训练过程中数据的索引配置文件。

yaml 配置文件中类别编号和目标名称是一一对应的。按钮、阀门、页面跳转图标等操作热点的类别名称要在模型训练之前确定下来，以保证之后识别结果的一致性。编辑好的 yaml 配置文件如图 3-3 所示

learnopencv > ! data.yaml

```yaml
path: D:\learnopencv\preparation\datasets
train: images/train
val: images/val
names:
  0: 自动
  1: 手动
  2: 电动调节阀
  3: 电动阀闸
```

图 3-4 yaml 配置文件示意图

使用统一的数据集组织方式以及配置文件管理，可以提高模型训练过程中数据读取的稳定性，为之后图像切片数据的自动加载和训练打下基础。

3.2 重叠切片与数据集转换

在模型训练前，先对原始监控界面图像做切片预处理，本节在 2.3 节理论的基础上，对原始监控界面图像进行切片预处理，得到模型训练所需要的数据集。

本文采用四区重叠切片法对原始监控界面进行分割。将完整的图像分成左上、右上、左下、右下四个区域，在相邻的两个区域之间留出 100 像素的重叠部分，处理过程如图 3-4 所示。

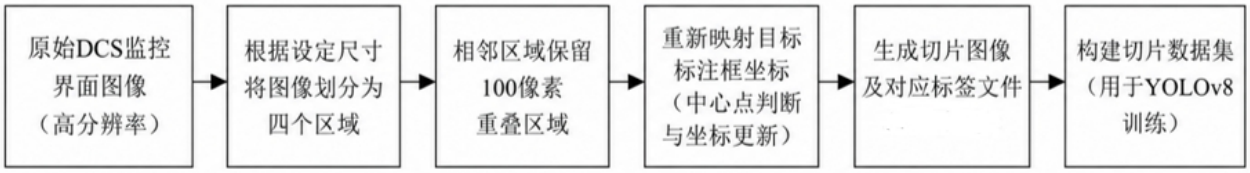


图 3-5 图像重叠切片处理流程

根据实验中 DCS 监控界面目标尺寸分布情况，本文最后将横向和纵向重叠宽度都设为 100 像素。该参数可以覆盖大部分的按钮和页面跳转图标尺寸，在减少目标边缘截断问题的同时又不会造成切片区域之间的重复面积过大。

设原始图像宽度与高度分别为 W 与 H，重叠区域宽度与高度分别为ΔW 与ΔH，则单张切片图像尺寸计算方式如公式(3-2)与公式(3-3)所示：

$$Crop_W=\frac{W+\Delta W}{2} \tag{3-2}$$

$$Crop_H=\frac{H+\Delta H}{2} \tag{3-3}$$

其中，$Crop_W$与 $Crop_H$分别表示切片后的宽度与高度。

图像切片的同时还要更新目标标注框的坐标。本文用目标中心点位置来判断，当目标中心点在当前切片区域内时就保留该目标，然后重新计算它的归一化坐标。目标中心点坐标更新过程用公式(3-4)与公式(3-5)所示：

$$x'=\frac{x-x_{min}}{Crop_W} \tag{3-4}$$

$$y'=\frac{y-y_{min}}{Crop_H} \tag{3-5}$$

其中，x 与 y 表示目标在原始图像中的中心点坐标，x_{min}与y_{min}表示当前切片区域左上角坐标，x'与 y'表示切片后的归一化坐标。

为了保证 YOLOv8 训练时背景样本的完整，在当前切片中如果没有目标的情况下，也会保存相应的空标签文件，使模型学会复杂的背景区域特征，提高非目标区域识别能力。经过切片处理后，原来的监控界面数据就被分割成许多个局部子图样本，从而增大了训练数据量。如图 3-5 为原始监控界面图之一，而图 3-6 为处理后带有重叠区域的子切片图。

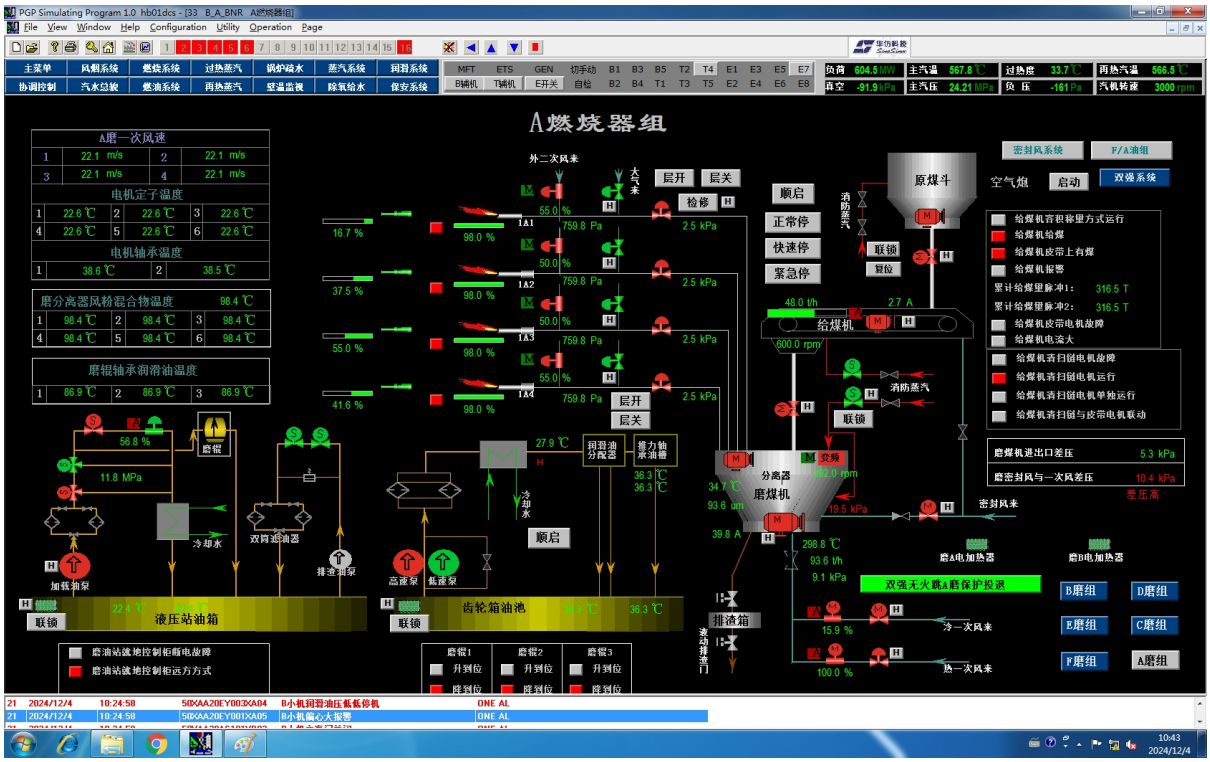


图 3-6 原始监控界面图



图 3-7 重叠切片处理结果图

3.3 YOLOv8s 模型训练参数配置

在数据集构建、切片处理完毕之后，本节将实验环境以及训练参数在训练前进行统一设置，从而使得结果稳定并且可复现。

3.3.1 模型训练环境配置

模型初始化使用 YOLOv8s 预训练模的型“yolov8s.pt”对 DCS 监控界面的数据集进行学习。预训练模型有基础的特征提取能力，可以减少由于随机初始化造成的不稳定现象，加快收敛速度。

另外为了保证训练数据可以被 YOLOv8 模型正确读取，本文用自定义的数据配置文件对数据集路径、类别数量、类别名称等信息进行统一管理，从而达到模型训练和数据集自动关联的目的。

3.3.2 模型训练参数设置

本文对 YOLOv8s 模型训练参数做了专门的设置。表 3-1 为主要的参数。

表 3-1 模型训练主要参数设置

参数名称	参数设置
输入分辨率（imgsz）	896×896
训练轮数（Epoch）	100

续表 3-1 模型训练主要参数设置

参数名称	参数设置
批大小（Batch size）	8
初始学习率（lr0）	0.01
最终学习率（lrf）	0.01
动量（momentum）	0.937
权重衰减（weight_decay）	0.0005
定位损失（box）	7.5
分类损失（cls）	0.5
马赛克增强关闭轮数（close_mosaic）	10
标签平滑（label_smoothing）	0.1

输入分辨率设为 896×896，以保留更多的界面局部细节。因此可以提高模型对于按钮、阀门、页面跳转图标等操作热点的特征提取效果。相比于模型默认的 640×640 输入尺寸，896×896 分辨率可以最大程度地保留图像内小目标的特征细节，从数据输入端避免小目标特征丢失、识别失效等问题。

训练轮数设为 100 轮，给模型足够多的时间来学习特征。由于输入图像分辨率较高，切片后数据量也比较大，所以 Batch Size 设为 8，减小 GPU 显存占用，保证训练过程稳定运行。

本文用的是 YOLOv8 默认的优化策略，初始学习率为 0.01。训练时学习率会随着迭代轮次的增多而逐渐降低，从而使后面的学习更加稳定。

另外 Momentum 参数设为 0.937 来提高梯度更新的稳定性，Weight Decay 参数设为 0.0005 用来抑制模型的过拟合问题，提高模型的稳定性。

考虑到 DCS 监控界面中一些操作热点的尺寸比较小，本文把定位损失权重参数 box 设为 7.5，在模型训练过程中更加重视目标边界框的学习。操作热点类别数量少，分类损失权重 cls 设为 0.5 来降低分类分支对整个训练过程的影响。

此外在训练时用到了 Mosaic 数据增强来提高模型对各种目标尺度、复杂的界面的适应性。因为 Mosaic 增强会对目标边界的学习造成一定的干扰，所以本文最后 10 轮训练中关闭了 Mosaic 增强，提高了模型后期定位的稳定性。

为了提高模型训练的鲁棒性，在此基础上又加入了标签平滑(Label_Smoothing)，将参数设为 0.1。该方法可以一定程度上解决模型因为单个标签而引起的过拟合问题，在复杂的监控界面中也有较好的泛化能力。

3.4 本章小结

本章主要对 DCS 监控界面操作热点识别实验的数据集构建和模型训练的过程进行了介绍。首先对原始监控界面图像进行人工标注，按照 YOLO 目标检测格式创建数据集并生

成 yaml 配置文件，从而达到训练数据和模型统一管理的目的。

本文针对监控界面目标尺寸小、局部区域信息密集的特性，用重叠切片法对原始图像进行预处理，并且同时完成标注框坐标映射和归一化更新。切片之后，原始监控界面就变成了许多局部子图样本，供模型训练使用。

模型训练阶段使用 YOLOv8s 网络结构，对输入分辨率、损失函数权重、学习率、数据增强方式等进行设置。提高输入分辨率以及定位损失权重，使训练过程更加重视目标边界位置的学习。

经过数据预处理以及训练参数的设置之后，模型就具备了进行实验验证的条件。下一章根据训练结果，对 YOLOv8s 在 DCS 监控界面操作热点识别的效果做实验分析和性能评价。

第 4 章 模型训练与结果分析

4.1 实验平台构建与数据统计

为了检验所提出火电厂 DCS 监控界面操作热点识别方法的有效性，本文使用 YOLOv8s 目标检测模型进行实验。根据自建数据集对模型的训练效果以及识别性能进行分析。实验内容有训练环境的搭建，数据集的统计分析以及模型识别结果的检验等。

4.1.1 实验平台的环境配置

本文实验所用的操作系统为 Windows，模型训练使用 Python 语言和 PyTorch 深度学习框架，目标检测模型使用 Ultralytics 官方提供的 YOLOv8 实现方案。为了提高模型训练效率，使用 GPU 加速环境进行实验。实验环境配置如表 4-1 所示。

表 4-1 实验环境配置

环境类别	配置项	具体参数与版本
硬件架构	核心处理器（CPU）	11th Gen Intel(R) Core(TM) i5-11400H @2.70GHz
	图形处理器（GPU）	NVIDIA GeForce RTX 3050 (7.9GB)
	运行内存（RAM）	16GB DDR4 3200MT/s
软件环境	操作系统	Windows 11
	并行计算平台	CUDA 12.1
	编程语言	Python 3.9.2
	深度学习框架	PyTorch 2.5.1

训练过程用 GPU 设备加速运算，统一所有的实验超参参与数据划分标准来保证实验的可复现。采用 YOLOv8 官方预训练权重，依靠自身具备的特征提取基础能力来加快模型的收敛速度，减弱由于随机初始化参数造成训练不稳定的状况。

4.1.2 数据集样本统计

本实验一共对 75 张 600MW 火电厂仿真机操控界面图进行了标注。经过重叠切片之后，数据量为 75×4=300 张，并用 4:1 的比例来划分。样本统计如表 4-2 所示。

表 4-2 操作热点数量统计表

系统	数据集划分	图片数量	占比	操作热点总数	平均单张热点数
600MW 仿真机	训练集	240	80%	8283	34
	验证集	60	20%	1899	
	总计	300	100%	10182	

由表 4-2 可知，每一个图片中的有大量且密集的操作热点，所以用 YOLOv8s 模型对这些操作热点进行识别是合适的。为了对数据集类别分布、目标尺寸特征进行分析，在训练时，YOLOv8 会自动产生数据集统计结果，如图 4-1 所示。

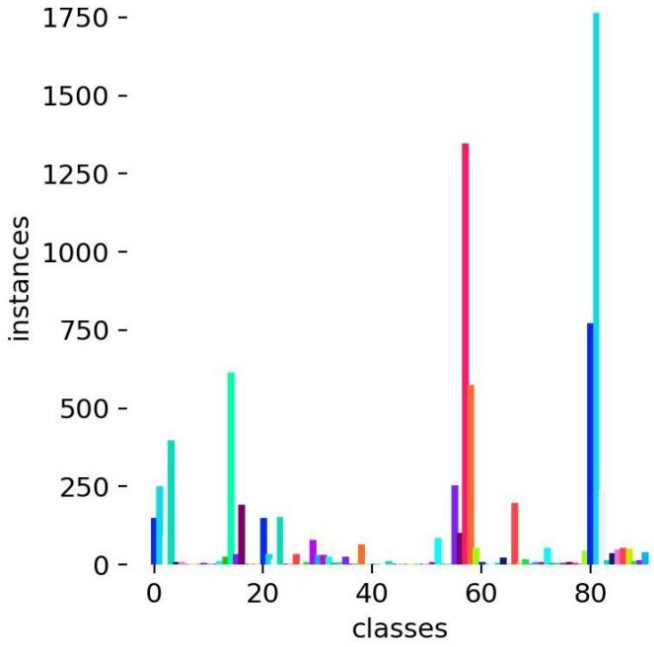


图 4-1 数据集标注统计结果

从数据集统计结果中可知各个类别之间样本数量不一样，有些操作热点样本数量远大于其它类别，说明数据集存在类别极度不均衡的现象。

4.2 YOLOv8s 模型训练过程分析

完成数据集的建立以及训练参数的配置之后，以 YOLOv8s 模型为载体进行火电厂 DCS 监控界面操作热点识别实验。在训练过程中，YOLOv8 框架会给到训练日志、样本的学习过程以及损失函数的变化曲线等，因此可以对模型的训练状态以及收敛情况做分析。

4.2.1 训练日志分析

模型训练开始之后，系统就会对训练集和验证集中的图像以及标签文件展开扫描，进而创建起缓存文件，从而提升后面训练阶段数据的读取速度。部分训练日志结果如图 4-2 所示。

```
train: Scanning D:\learnopencv\preparation\datasets\labels\train... 133 images, 3 backgrounds, 0 corrupt:
train: Scanning D:\learnopencv\preparation\datasets\labels\train... 240 images, 11 backgrounds, 0 corrupt
train: New cache created: D:\learnopencv\preparation\datasets\labels\train.cache
val: Fast image access  (ping: 0.10.0 ms, read: 689.0100.8 MB/s, size: 84.2 KB)
val: Scanning D:\learnopencv\preparation\datasets\labels\val.cache... 60 images, 5 backgrounds, 0 corrupt
```

图 4-2 模型训练日志输出结果

由图中的运行日志所示，可以提取到以下信息：

（1）YOLOv8 训练开始的时候，会自动对训练集和验证集的图像数目、目标实例数目以及背景样本数目进行统计。在每一个训练过程中输出 GPU 显存占用、损失函数的变化、模型评价指标。

（2）系统在训练集、验证集中各有 11 张、5 张图片没有标签的纯背景图(backgrounds)，即这些图片中没有操作热点。

（3）未发现文件损坏(0 corrupt)。

（4）系统自动生成了缓存文件‘.cache’以提升后续迭代的效率。

然后进入迭代阶段，控制台输出的训练日志如图 4-3 所示。

```
Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
8/100      4.33G      1.666      4.874      1.202        384        896: 100% ━━━━
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95):
             all         60       1899     0.0238     0.0573     0.0225     0.0157

Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
9/100      4.85G      1.687      4.551      1.223        637        896: 100% ━━━━
           Class     Images  Instances      Box(P          R      mAP50  mAP50-95):
             all         60       1899     0.0245     0.0768     0.0321     0.0218

Epoch    GPU_mem   box_loss   cls_loss   dfl_loss  Instances       Size
10/100     4.68G      1.639      4.308      1.213        416        896: 60% ━━━━
```

图 4-3 迭代阶段的日志输出结果

同样可以获取到以下信息：

（1）训练前 20 轮，三个损失值较高，训练轮数增加后，各项损失均降低。Precision、Recall、mAP 等指标也有所提高。

（2）在验证集中，60 张图片里有 1899 个目标，与表 4-2 中统计的数量相同。

（3）模型训练过程中 GPU 显存占用在 4 到 5G 之间波动，说明批大小和输入分辨率满足实验环境的要求，不会出现性能不足的情况。

从训练日志可知，模型可以读取图像、标签数据，在训练过程中没有因为数据损坏、

显存溢出等原因出现异常，说明目前数据集的组织形式和训练环境满足 YOLOv8s 模型的训练要求。

4.2.2 模型训练结果

经过 100 轮训练之后，YOLOv8 会自动创建出 runs/detect 目录下训练的结果文件，这里面包含：

（1）模型权重文件：训练完成后，模型保存两个核心权重文件，一个是最后一轮训练得到的 last.pt 以及根据验证集测试结果选取的最佳模型 best.pt。后续实验与测试均采用 best.pt 作为测试模型。

（2）图 4-4 是模型的学习过程图，在训练过程中上图为训练截图，下图为部分放大图。YOLOv8 会自动保存部分训练批次的可视化结果，用来观察模型的学习情况。

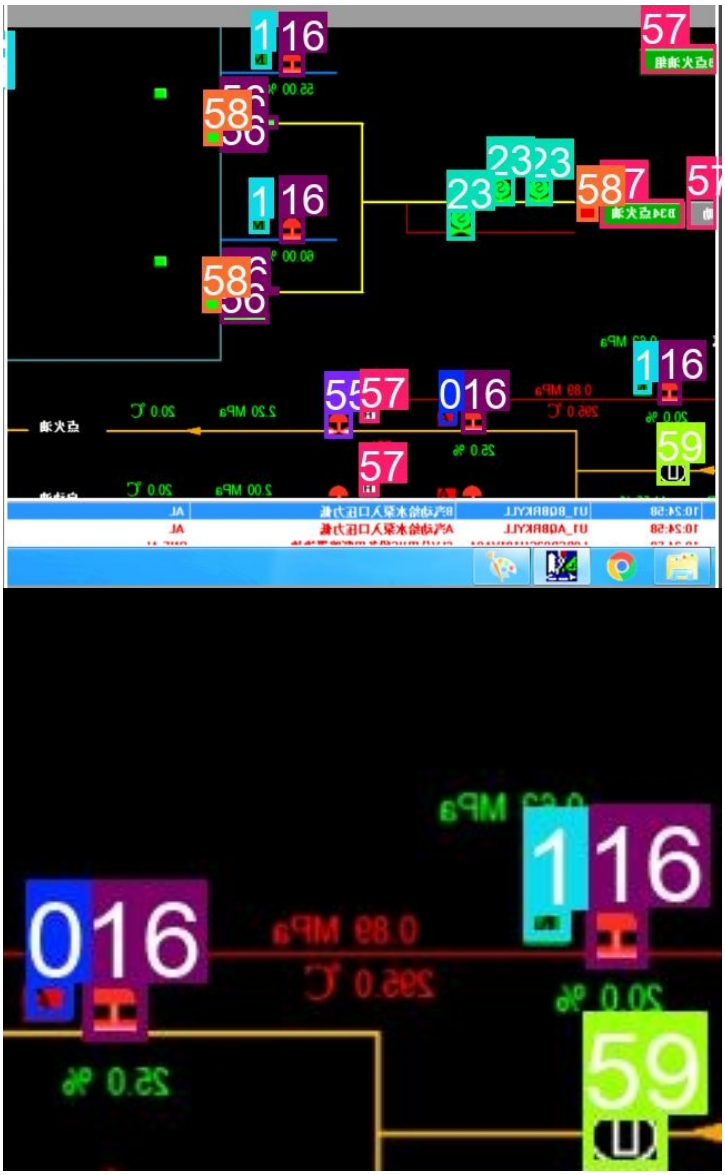


图 4-4 模型训练可视化结果

（3）为了对验证集真实标签和模型预测之间的差异进行比较分析，可以将二者拿出来进行对比。图 4-5 为验证集中各个目标所对应的方框位置以及类别情况，主要用以检验数据标注是否准确。



图 4-5 验证集真实标签可视化结果

图 4-6 是模型在验证集上的预测结果图。与图 4-5 进行对照可以看到：模型能较准地判断出目标的位置和类别。即便在目标比较密集的地方，模型仍然能较稳定地提取出监控界面里的目标特征。

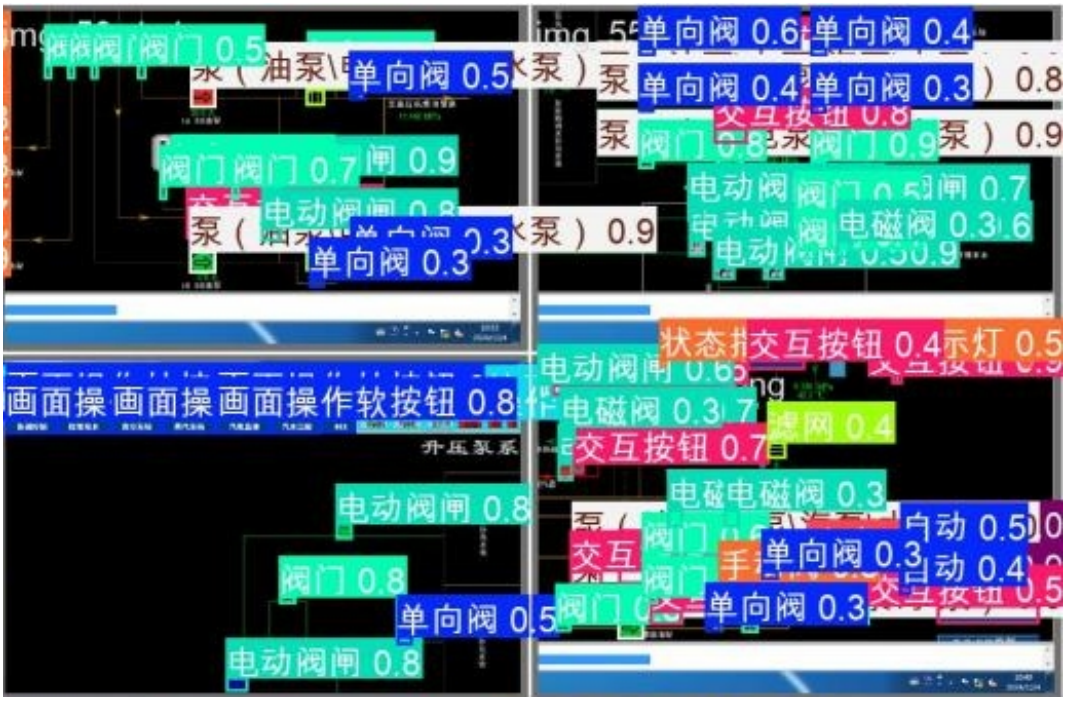


图 4-6 验证集预测的可视化结果

从综合训练过程中得到的可视化结果可知，经过改进的 YOLOv8 模型可以逐渐学会 DCS 监控界面各个操作热点的目标特征，在训练过程中目标定位和类别识别比较稳定，为后面实验测试以及性能分析打下了基础。

（4）损失函数和评估指标变化图。图 4-7 给出了训练集和验证集上的损失函数变化曲线，还有 Precision、Recall、mAP50、mAP50-95 的变化情况。

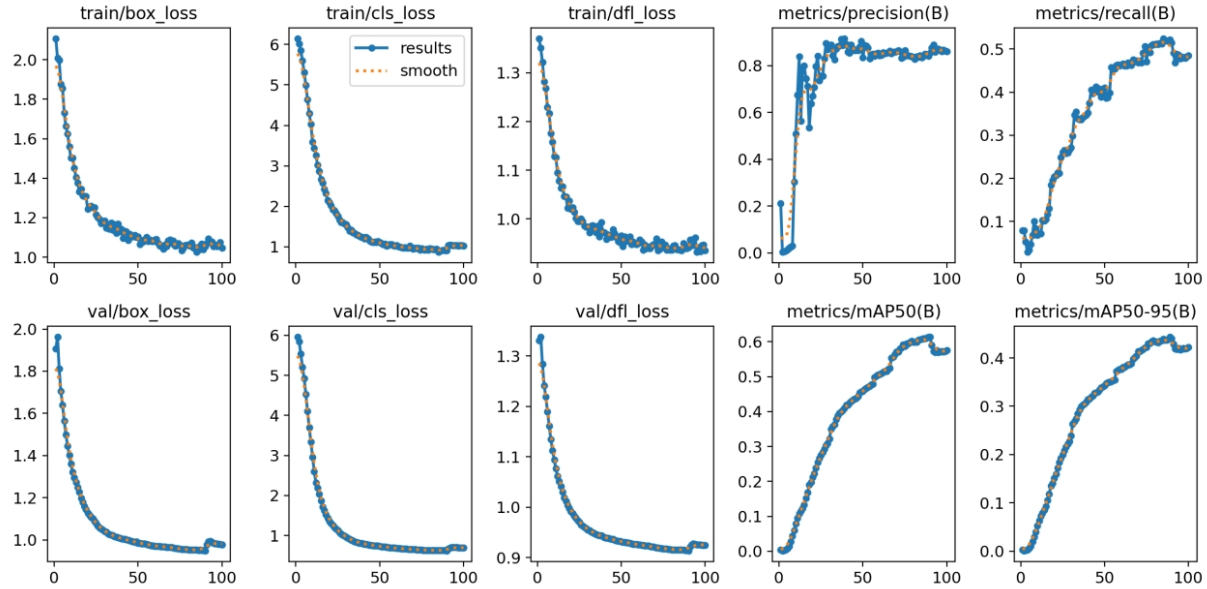


图 4-7 训练评价指标图

从图中可以发现，训练集中三个损失函数值随着时间的推移都在不断减小，最后趋于稳定，说明模型在训练的过程中不断地提高目标定位、类别分类和边界框回归的能力。

验证集三个损失函数都呈下降趋势，说明模型对训练集和验证集都有较好的学习效果，没有出现过拟合现象。

评价指标上 Precision 和 Recall 都提高了。Precision 在训练后期保持较高的水平，误检率降低，Recall 也逐渐提高，目标检测能力变强。

mAP50 和 mAP50-95 随着训练轮次的增加一直上升，最后趋于稳定。mAP50 是用较宽松的 IoU 来衡量检测性能，mAP50-95 表示不同的 IoU 阈值下的综合能力。整体结果表明模型可以基本学习到操作热点特征。

4.3 模型识别性能验证

完成模型的训练和初步验证之后，就要用独立的代码来对它的实际识别性能进行测试。本节的测试环节会独立训练环境，只测试训练完成之后最佳权重文件(best.pt)的泛化能力。

4.3.1 测试流程设计

为了保证测试阶段和训练阶段输入图像尺寸的一致性，减小由于图像缩放造成的特征变化影响，本文把测试输入图像尺寸设为 896×896。另外为了减少置信度较低的预测结果

对检测结果的影响，在实验中设置了置信度阈值 conf=0.5，只保留置信度较高的检测结果。

测试时系统先加载训练阶段得到的最佳权重 best.pt，对输入图像做目标检测推理，用 GPU 加速计算来提高检测速度。模型生成后，系统自动给出检测结果图像，检测框、类别名称以及置信度信息会一同展示出来，从而分析出模型对于操作热点的识别状况。模型测试流程如图 4-8 所示。

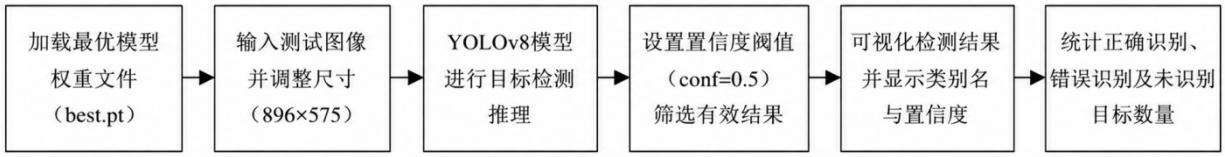
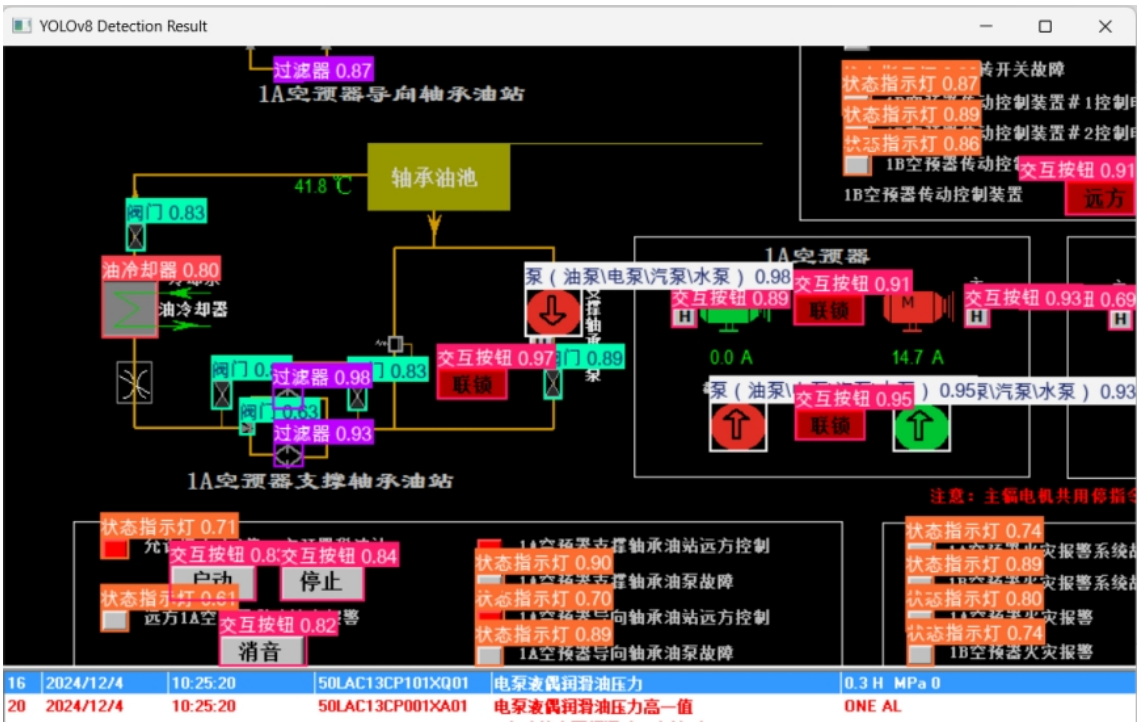


图 4-8 模型测试流程

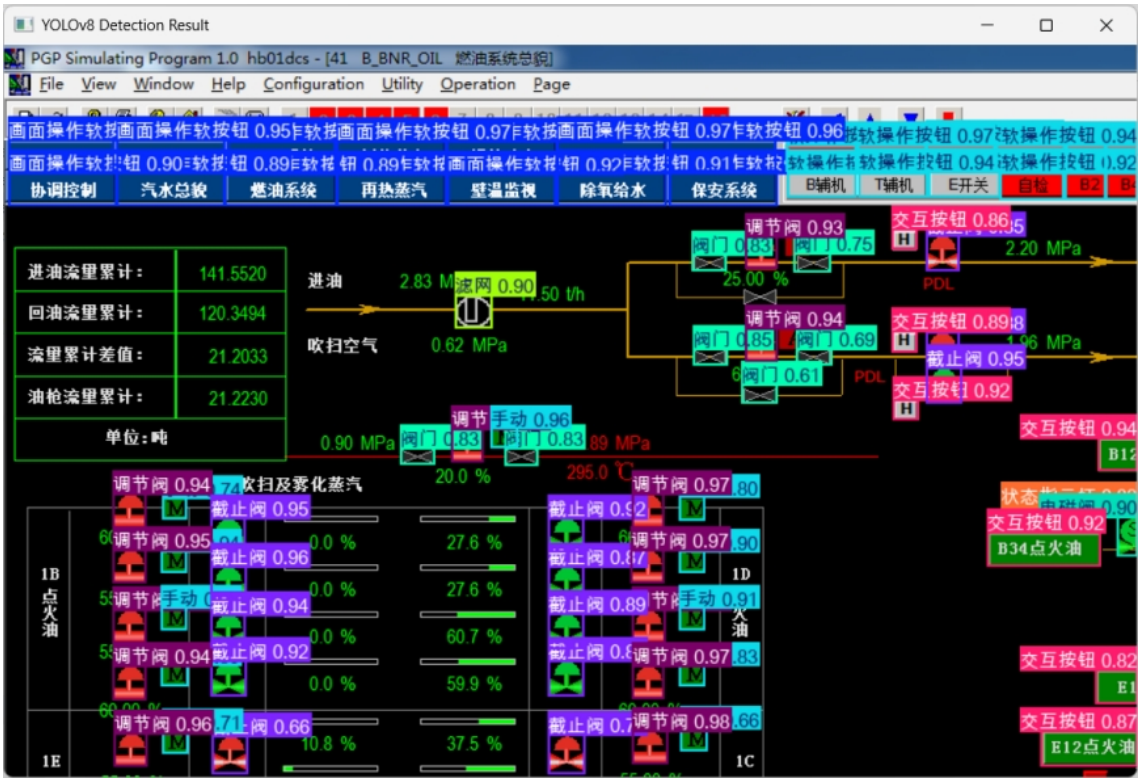
经过上述测试流程之后，模型可以实现对火电厂 DCS 监控界面中操作热点的自动识别以及结果可视化，为后面模型测试结果分析及性能评价打下基础。

4.3.2 测试结果可视化分析

程序运行结束后，本文选取了三张具有典型操作热点的截图，具体如图 4-9 所示。



(a)



(b)



(c)

图 4-9 模型测试结果图

从图 4-9 所展示的情况可以了解到，该模型能够比较好地完成监控界面操作热点的检测任务，对于不同类别的目标，也能够进行有效的区分。虽然模型在目标分布比较密集的区域里，可以较好地完成目标定位和类别识别，但是，在小目标的特征提取能力以及复杂

环境下的检测能力这两个方面，都得到了一定的提升。

图 4-9(a)为监控界面中状态指示灯和交互按钮检测结果，小尺寸目标密集分布时也能基本识别出来；图 4-9(b)为复杂流程图界面多类别热点检测结果，各类别之间区分较好；图 4-9(c)为复杂背景条件下检测结果，边缘处有少量漏检，但总体效果稳定。

为了更客观地评价模型检测性能，本文又选取没有参加训练过程的验证集图像作为测试样本，在置信度阈值为 0.5 的情况下，对模型检测结果进行了统计分析，统计结果见表 4-3 所示。

表 4-3 操作热点检测结果统计表

统计指标	数量	判定标准	占比
正确识别	1761	预测框位置准确且类别标签与真实标签一致	92.73%
错误识别	7	背景区域误检或类别识别错误	0.37%
漏检	131	图像中存在目标但模型未成功识别	6.90%
总数	1899		100%

由表 4-3 中可以发现，模型在验证集上正确检测的数量较多，误检较少，说明它已经可以很好地学习 DCS 监控界面各种操作热点特征。漏检依然存在，大部分集中在占比较小的目标区域。该类目标尺寸小、分布密，部分区域特征不明显，识别困难。高频出现的热点检测结果比较稳定。

本节测试用人工统计的方法来分析检测结果，和训练阶段根据 IoU 阈值计算出的 Precision、Recall 以及 mAP 指标有差别。训练阶段用预测框和真实框的重叠程度来判定，人工统计更重视目标是否被识别。因此，轻微的位置偏差但是仍然覆盖目标区域的结果，在本节中仍然判定为正确的检测。

从综合训练阶段和测试阶段的结果可知，模型可以比较稳定的完成火电厂 DCS 监控界面操作热点的检测工作。不仅可以准确定位大多数的操作热点，而且在监控界面和密集目标场景中也能得到较好的检测效果。

4.3.3 泛化能力测试

本节在验证集测试的基础上，又选取了手机拍摄的监控界面图像作为测试样本，来考察模型的泛化能力。手机拍摄的图像比直接截取的界面图像更接近工程实际中的输入场景，也更接近工程实际中的应用。部分测试结果如图 4-10 以及图 4-11 所示：



图 4-10 正视拍摄测试结果

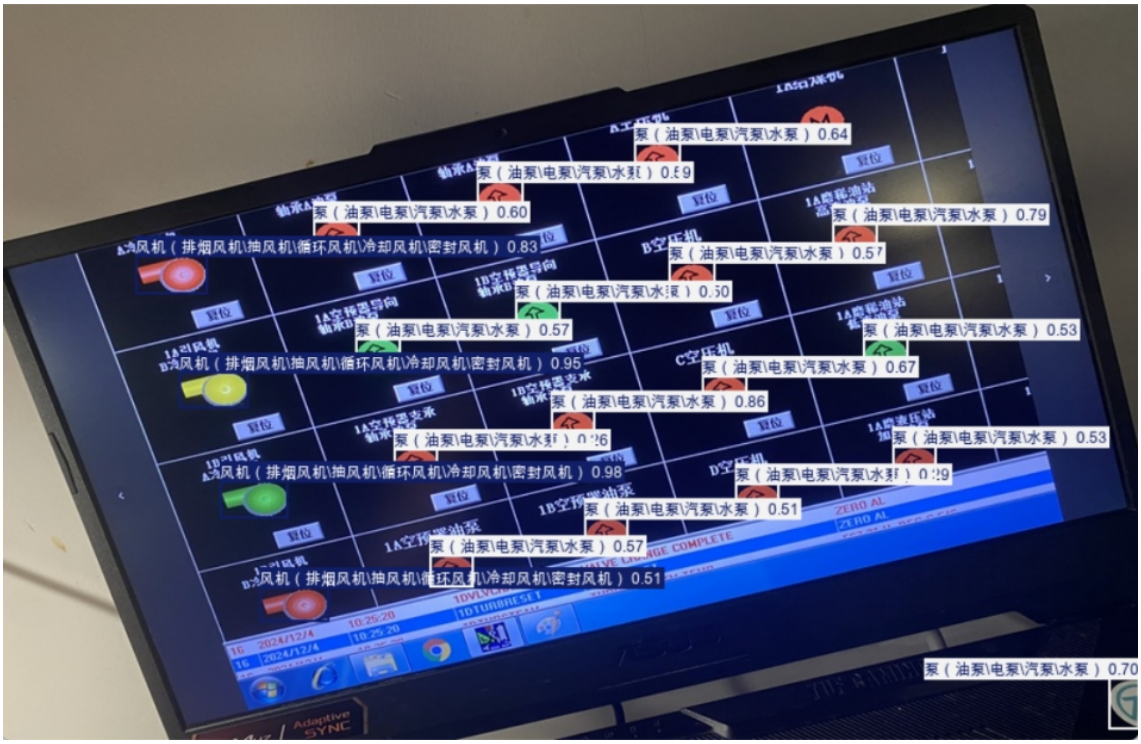


图 4-11 倾斜拍摄测试结果

实验过程中用同一个移动设备对 DCS 监控界面进行拍摄，尽量保持拍摄距离、光照条件、画面清晰度一致。并调整图像分辨率，保证和原来一致。测试时选择了正视拍摄、轻微倾斜拍摄等几种场景来观察模型在各种情况下的检测效果。

从测试结果可以得知，对于界面中交互按钮、软操作按钮等目标，模型仍然可以得到较好的检测结果，说明其对于界面目标的特征有一定的鲁棒性。

另外，当图像有轻微倾斜的时候，一些小尺寸的目标还会出现部分漏检的情况，部分预测框的置信度也会出现一定程度的下降。主要是由于手机拍摄条件下存在局部模糊、亮度变化等外界因素的影响，也存在界面外部因素的干扰，使得部分目标特征受到影响。

综合测试结果表明，本文所提出的操作热点识别方法可以适用于标准截图场景，也可以一定程度上适应复杂输入环境。但是对复杂拍摄条件下小目标的检测性能还有待提高。

4.3.4 切片还原与非极大抑制处理

在做完四区重叠切片的目标检测之后，各子切片的检测结果都在局部的坐标系里，所以后面得把它们做统一的坐标还原。图 4-12 给出了切片还原与后处理的整体流程。

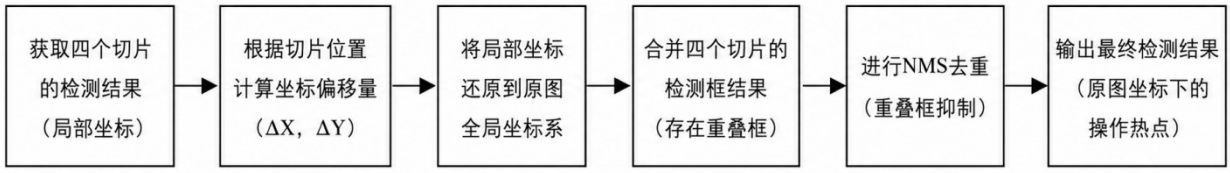


图 4-12 切片还原具体步骤

在这里，首先需要依据切片在原图中所处的位置偏移量，把局部的检测框进行重新映射，让它回到全局坐标系当中，这样一来，所有的检测结果就能够在原始的监控界面里得到一个统一的表达。因为切片相互之间是存在着重叠区域的，同一个目标很容易就会遭到反复的检测，所以在对结果进行融合时，引入了非极大值抑制（NMS），去进行去重的处理，把那些置信度比较高的检测框给保留下来，通过这样的做法，来降低重复框所带来的干扰。经过上述处理后，最终呈现的结果如图 4-13 所示。

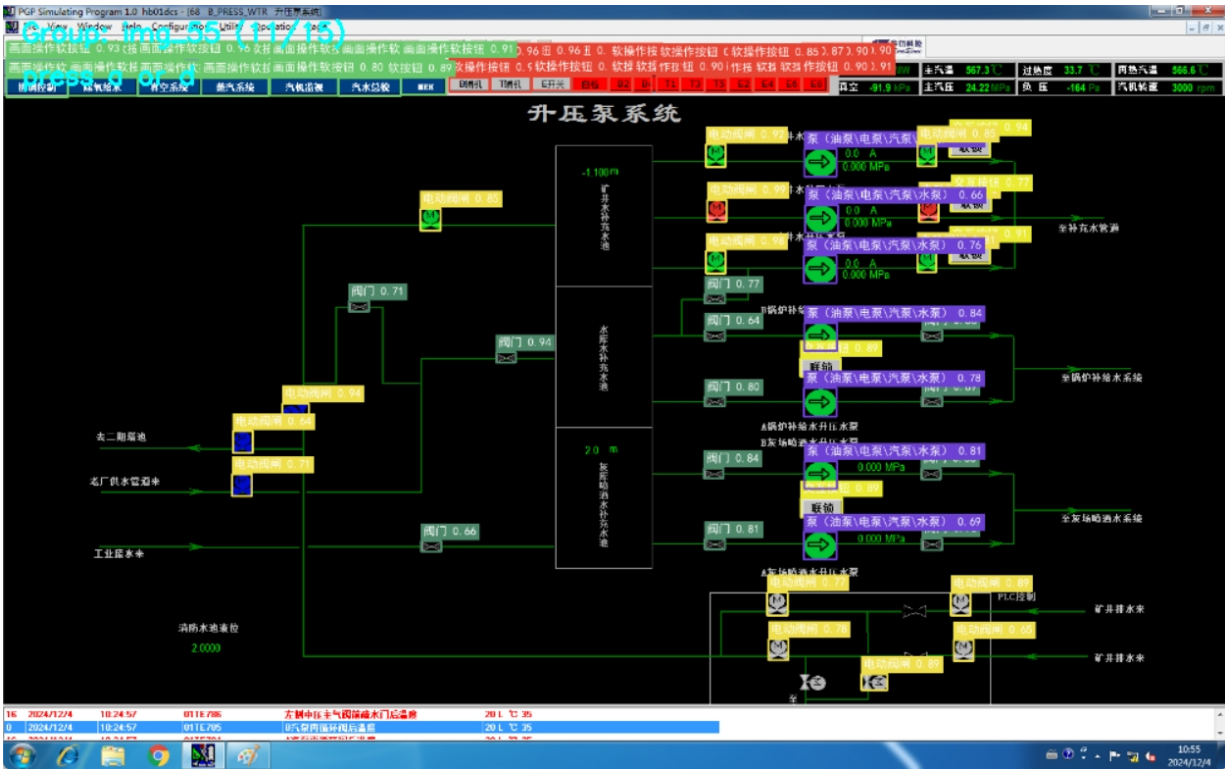


图 4-13 最终测试结果展示

4.4 消融实验与模型优化分析

为了进一步检验本文所用到的图像切片方法、参数优化策略对于火电厂 DCS 监控界面操作热点识别效果的影响，本节将做消融实验，使用不同的实验条件下得到的效果最好的权重文件 best.pt，参考训练生产的 result.csv 数据，对模型检测性能进行分析，为模型的优化提供方案。

为了检验图像切片方法以及训练轮数对模型检测性能的影响，在相同的环境、数据集下做了消融实验，选择每个模型中 mAP50-95 最高的训练轮次，比较不同方案的检测结果。

首先对采用图像切片方式与不采用图像切片方式进行了实验对比，实验结果见表 4-4。

表 4-4 图像切片消融实验结果

实验方案	应用图像切片	mAP50	mAP50-95	Precision	Recall
原始 YOLOv8s	否	0.09415	0.07426	0.54362	0.08507
本文方法	是	0.61384	0.44348	0.83945	0.52131

由表 4-4 可知，图像不加切片时 mAP 值很低，召回率也很低，说明模型不能识别出大部分热点。加入图像切片之后，模型的各项指标都得到了明显的提高，说明模型在原始图像中很难识别出小目标，但是图像切片方法可以有效地增强小目标区域的特征，从而大大提高模型对于操作热点的检测能力。

本文还对不同的训练轮数下模型的性能做了实验对比，结果见表 4-5 所示。

表 4-5 不同训练轮数实验结果

Epochs	mAP50	mAP50-95	Precision	Recall
50	0.23701	0.16928	0.79816	0.20293
100	0.61384	0.44348	0.83945	0.52131
200	0.75235	0.53190	0.85455	0.69237

由图可知，训练轮次越多，各个评价指标逐步提升。在 50 轮训练过程中，模型还处在目标特征初步学习阶段，对于一些复杂的区域以及密集的小目标的特征提取能力还比较弱，所以整体检测性能较低。200 轮训练结果比 100 轮好，说明模型在 100 轮训练后还没有完全完成特征学习。继续增加训练轮数之后，模型对于操作热点区域的特征提取能力得到了进一步的提高，总体检测性能有所改善。

4.5 本章小结

本章主要对火电厂 DCS 监控界面操作热点识别实验中 YOLOv8s 模型的训练、测试以及优化结果进行分析。搭建实验环境、统计数据集，整理切片后样本分布情况。训练阶段通过查看日志、损失的变化、验证集的结果来分析模型是怎样的学习操作热点特征的，最后模型趋于稳定。

测试阶段用最佳权重文件 best.pt 对验证集进行检测，结果表明模型可以比较准确地识别出按钮、阀门、页面跳转图标等操作热点，在目标密集区域也有较好的效果。但是低频热点仍然存在漏检情况，主要出现在小目标或者特征不明显的区域。消融实验中对图像切片方法以及训练轮数进行比较，结果说明切片可以改善小目标的表现，训练轮数增多会使得模型整体性能提高。本实验还对测试图片进行切片还原以及 NMS 处理，将原图的识别效果展示出来。

最后，本实验用手机拍摄图像做测试，在远离拍摄和倾斜角度的情况下，模型仍然可以完成主要目标的检测和定位，结果比较稳定，有一定的泛化能力。

从综合结果可以看出，YOLOv8s 加上图像切片的方法可以完成 DCS 监控界面操作热点的识别任务，在小目标检测上也具有一定优势。

第 5 章 总结与展望

5.1 工作总结

本文以火电厂 600MW 仿真机监控界面为研究对象，针对监控界面操作热点目标尺寸小、分布密集、识别困难等状况，对基于 YOLOv8s 的目标检测模型进行操作热点识别的研究。根据数据集制作、图像切片处理、模型训练、实验测试等过程建立并检验火电厂 DCS 监控界面操作热点识别模型。本文主要总结如下：

（1）针对火电厂监控界面缺少专用数据集的问题，本文自行构建了操作热点数据集。使用 LabelImg 工具对界面中按钮、阀门、状态指示灯和页面跳转图标等操作区域进行人工标注，将各类别进行统一划分并标注规范，为之后模型训练提供较为完整的数据基础。

（2）对于监控界面目标检测中出现的大量小目标、分布密集的情况，在对原始数据进行预处理时，采用图像重叠切片的方式，使单个目标在一张图片中的占比增加，尽量减少由于降低图片分辨率造成的信息丢失问题。在此基础上采用 YOLOv8s 模型进行训练，通过改变输入特征的大小、增加训练时间和改变损失函数权重等方式提高模型对于重要位置小目标的检测能力以及鲁棒性。

（3）对模型训练和测试过程中使用到的所有相关的重要信息，包括训练日志、损失曲线、验证集上的预测结果、最终测试结果等都做了详细的记录并进行了分析，以此来体现该模型的实际应用情况。从实验结果可以看出，在存在大量背景噪声或者目标分布密集的时候，所提出的算法具有较好的鲁棒性，在监控界面上可以有效地对操作热点进行定位。

（4）实验针对图像切片方法以及超参数的选择开展了大量的实验工作，来对它们所产生的影响进行充分的考察，在此基础上所得到的结果是：本文所提出的方法能够显著地提高小目标被检测出来的概率，而且增加训练的轮数也能够进一步地改善整个测试的效果。随后，实验把测试结果的切片进行了还原，并在原图上进行了展示。实验还使用了手机去采集正视以及倾斜视角下的数据，并开展了实际测试工作，这也表明方法具有良好的鲁棒性和泛化能力。

本文利用了 YOLOv8s 以及基于图像切片的 DCS 监控界面操作热点检测的方法，能够比较好地对小目标检测问题进行解决，在一定程度上是具有实用意义的。

5.2 后续工作及展望

虽然本文已经完成了火电厂 DCS 监控界面操作热点识别模型的建立和实验验证，但是由于实际工业环境的复杂多变，相关的研究还存在着一定的发展空间，以下将从以下几个方面进行研究。

（1）本文使用图像切片的方式提高小目标检测的效果，但是切片之后会破坏原始监控界面的整体连续性。之后可以继续完善切片坐标映射以及结果融合的方法，把各个区域的检测结果重新映射到原始的监控画面上去，从而达到完整的界面实时检测和显示的效果，

提高系统的可视化程度。

（2）针对目前测试流程里还需要依靠人工来逐张切换图像的情况，在后续的工作当中，可以借助本文所开发出来的图像拼接以及按键切换的逻辑，对人机交互的功能进行改进，从而让监控界面的检测结果能够被快速地浏览并实现自动切换，进而把大规模数据集的测试和复核的速度给提升上去。另外，还可以为之后监控界面的自动巡检以及在线检测工作提供基础层面上的支持。

（3）本文主要针对静态监控界面开展目标检测研究，之后可以融合视频流处理技术，就实时运转中的 DCS 监控画面实施连续识别与动态剖析，进而提升模型在实际应用环境里的运用水平。

（4）还可以把操作热点识别结果同电厂运行逻辑、设备状态信息以及操作行为分析结合起来。通过对操作人员点击位置、操作顺序进行分析，可以实现对异常操作识别、误操作预警、辅助决策等目的的功能，进而提高火电厂运行过程中安全、智能程度。

参 考 文 献

[1] 高隽. 人工神经网络原理及仿真实例[M]. 机械工业出版社, 2003, 8.
[2] 蒋宗礼. 人工神经网络导论[M]. 高等教育出版社, 2001. 8.
[3] 杨建刚. 人工神经网络实用教程[M]. 浙江大学出版社, 2001. 1.
[4] 王伟. 人工神经网络-入门与应用[M]. 北京航空航天大学出版社. 1995. 4
[5] 韩力群. 人工神经网络教程[M]. 北京邮电大学出版社. 2006. 12.
[6] (美)Tom M. Mitchel 曾华军等译. 机器学习[M]. 机械工业出版社, 2003, 1.
[7] 张立明. 人工神经网络的模型及其应用[M]. 复旦大学出版社, 1993. 7.
[8] 沈庭芝, 方子文. 数字图像处理及模式识别[M]. 北京理工大学出版社, 1998. 6.
[9] 王耀南. 计算机图像处理与识别技术[M]. 北京:高等教育出版社, 2001.
[10]胡小锋, 赵辉. Visual C++/MATLAB 图像处理与识别实用案例精选[M]. 北京:人民邮电出版社, 2004.
[11]毛星云, 冷雪飞. OpenCV3 编程入门[M]. 第一版. 北京:电子工业出版社, 2015. 2.
[12]望熙荣, 望熙贵. OpenCV 和 Visual Studio 图像识别应用开发[M]. 人民邮电出版社. 2017. 10.
[13]尹宏鹏, 陈波, 柴毅, 等. 基于视觉的目标检测与跟踪综述[J]. 自动化学报, 2016, 42(10):1466-1489.
[14]白雨生. 基于深度学习的火电机组仿真机画面识别研究[D]. 华北电力大学, 2023.
[15]彭明霞, 夏俊芳, 彭辉. 融合 FPN 的 Faster R-CNN 复杂背景下棉田杂草高效识别方法[J]. 农业工程学报, 2019, 35(20):202-209.
[16]张恒博, 欧宗瑛. 一种基于色彩和灰度直方图的图像检索方法[J]. 计算机工程, 2004(10): 20-22.
[17]李波燕, 张勇, 袁德荣, 等. 基于注意力机制的手写体数字识别[J]. 计算机科学, 2022, 49(S2):626-630.
[18]Redmon J, Farhadi A. Yolov3: An incremental improvement[C]. Computer vision and pattern recognition. Berlin/Heidelberg, Germany: Springer, 2018, 1804: 1-6.
[19]Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]. European Conference on Computer Vision. Springer, 2016:21-37.
[20]Liu C Y, Wu Y Q, Liu J J, et al. Improved YOLOv3 Network for Insulator Detectionin Aerial Images with Diverse Background Interference[J]. Electronics, 2021,10(7).771-771.
[21]王超. 火电机组仿真机监控参数图像识别及应用研究[D]. 华北电力大学, 2023.
[22]宋红萍, 刘宏超, 全安寿, 等. 基于小波网络和多模块网络的数字识别[J]. 中文信息学报, 2000, 14(2): 37-42.
[23] 赵海涛, 於东军. 基于特征选择的字符识别[J]. 计算机工程与应用, 2002, 38(21): 34-35.
[24]张宁, 郭增军, 李静. 基于图像处理的水表智能检定系统研究[J]. 北京石油化工学院学报, 2017, 25(1): 57-64.
[25]Asif M, Bin Ahmad M, Mushtaq S, et al. Long multi-digit number recognition from images empowered by deep convolutional neural networks[J]. The Computer Journal, 2022, 65(10): 2815-2827.
[26]李娜. 基于深度学习的仪表示数图像识别方法研究[D].苏州科技大学,2021.
[27]梁凯文,孙海江,江山,等.基于 YOLO11 的红外小目标检测和编批算法设计[J].机电工程技术,2026,55(07):84-90.
[28]Lu W ,Zheng H ,Xiao S , et al.Application of the Improved YOLOv8 Algorithm for Small Object Detection in X-ray Weld Inspection Images[J].Journal of Nondestructive Evaluation,2025,44(3):91-91.DOI:10.1007/S10921-025-01235-4.

致　　谢

时光冉冉，聚散离别终有时。四年的本科生涯进入尾声，但求学之路并未结束。回望来路，既有收获的喜悦，也有探索过程中的迷茫与坚持。纵然此刻有诸多不舍，却道不尽心中谢意。

首先，由衷感谢我的导师马进副教授对我的耐心教导。在论文的选题、实验的设计以及论文撰写修改过程中，老师始终给予我耐心细致的指导与严谨认真的学术建议。从研究思路的梳理到实验方案的完善，从论文表达的规范到细节问题的修正，都倾注了大量心血，使我在学术能力与科研思维方面受益良多。在此谨向导师致以最诚挚的敬意与感谢。

其次，感谢学校为我提供了良好的学习环境与科研平台。在四年的学习过程中，学校完善的课程体系、严谨的学术氛围以及丰富的实践机会，为我的专业成长奠定了坚实基础，使我得以在不断探索中提升自我、拓展视野。

最后，衷心感谢我的父母。在求学过程中，是你们在背后默默支持与鼓励，给予我最坚定的理解与陪伴。无论顺境还是困难，都是你们的关心与付出让我能够安心学习、不断前行。这份恩情难以言尽，唯有以更好的自己作为回报。

四年光阴虽短，却意义深远。谨以此致谢，感谢所有在我成长道路上给予帮助与温暖的人。